

ThaiSLM v5 — Latent Space & Vocabulary Bank Report

(Stage 4)


Scope. รายงานนี้ดูเฉพาะ "พื้นที่ตัวแทน" (representation / latent / embedding space) ของ encoder v5 และ vocabulary bank ที่ใช้ค้นคำ — หน้าตาของพื้นที่, ค่าเกาะกลุ่มกันอย่างไร, CosFace proxies ทำอะไรตอน training, ตอน inference ดึงคำจาก bank อย่างไร, และแม่นยำแค่ไหน

Data. ใช้ embedding จริงของ run ที่ deploy (artifacts/v5/runs/train_all-20260914-170615-europe-west4, best step 400): 11,622 isolated clips × 768-d (TTRS 5,036 · TSL-ONE-S 4,148 · TSL51 2,113 · YouTube 245 · `<nu11>` 80 clips) ทั้งแบบ zero-shot (Uni-Sign ก่อน fine-tune) และ v5. ทุกตัวเลขในรายงานคำนวณใหม่จากไฟล์เหล่านี้ด้วย `scripts/v5_latent_report.py` → `artifacts/reports/v5_latent_report.json`, ระบุอยู่ใน `result_reporting/latent_v5/`. ไม่มีการ tune อะไรบน data_test (ส่วน §8 เป็นการส่องดูอย่างเดียว).

1. สรุปสั้น (TL;DR)

คำถาม	คำตอบ
พื้นที่หน้าตาเป็นอย่างไร	hypersphere 768-d (L2 norm = 1) ใช้งานจริง ~73 มิติ (participation ratio), คำเป็นกลุ่มก้อนเล็กแน่น แยกกันด้วยมุม
ค่าเกาะกลุ่มดีขึ้นไหม	ดีขึ้นชัด: คำเดียวกันต่างคน cos 0.60 → 0.70 , คำต่างกัน cos 0.20 → 0.06 ; 92 % ของ concept "แน่นกว่าเพื่อนบ้านที่ใกล้ที่สุด" (zero-shot 61 %)
คนทำต่างกันทำให้ปั่นไหม	แทบไม่: KNN-5 เป็นคนเดียวกัน 0.45 → 0.43 ขณะที่ KNN-5 เป็นคำเดียวกัน 0.78 → 0.84 ; other-concept-same-signer ≈ other-concept-other-signer (0.065 vs 0.059)
CosFace ทำอะไร	ผลัก margin เชิงมุม: query ที่ห่าง prototype ผิดตัวที่ใกล้สุด ≥ m=0.25 เพิ่มจาก 5 % → 35 % ; prototype ของคำหลายคนแยกออกจากกัน (nearest-other cos median 0.73 → 0.66)
ความแม่นยำค้นคำ (held-out signer)	TSL-ONE-S R@1 0.81 → 0.88 (R@5 0.96); TSL51 MP 0.69 → 0.70 (R@5 0.90); RTMW 0.55 → 0.52; TTRS คนใหม่ 0.13 → 0.17; YouTube 0.29 → 0.36
จุดอ่อน	คำที่มีคนทำใน bank แค่ 1–2 คน (R@1 ≤ 0.18), hub concepts ดึง error 24 %, pose คนละ extractor (RTMW) ยังห่าง, ทำเร็ว/ต่อเนื่องใน data_test ตกไปใกล้คำอื่น

2. พื้นที่ตัวแทนถูกสร้างและใช้อย่างไร



Embedding. ทุก clip (หรือทุก window ตอน inference) → vector 768 มิติความยาว 1; ความเหมือน = cosine = dot product.

Vocabulary bank. ไม่ใช่ classifier head — เป็นตาราง instance embeddings พร้อม concept id:

bank	instances	ใช้ทำอะไร
eval bank	8,672 (clip role = train เท่านั้น)	วัดผล held-out signer ทุกตัวเลขในรายงานนี้
deploy bank	12,843 (ทุก labeled clip + 1,301 คำที่ align จากประโยค TSL51)	ใช้จริงใน pipeline / lab.ipynb / data_test
null prototype	mean ของ <null> train embeddings (TSL51 null_act, rest, straddle)	บอกว่า window นี้ "ไม่ใช่ท่า"

ข้อดีของ bank: เพิ่มคำ/คนใหม่ได้ทันทีโดยไม่ต้อง train ใหม่ (append embeddings), และแต่ละคำมีหลาย "ท่าย่อย" (variant) ได้ เพราะใช้ top-2 instance ไม่ใช่ค่าเฉลี่ยเดียว.

Concept vocabulary. 4,570 concepts + <null>; ใน eval bank มี 4,528 concepts แต่มีเพียง **379** concepts ที่มี ≥ 2 signers (ที่เหลือ 4,149 มีคนทำคนเดียว ส่วนใหญ่จาก TTRS) — ตัวเลขนี้อธิบายหลายอย่างใน §5–6.

3. หน้าตาของ latent space ทั้งหมด




Fig 1. UMAP (cosine) ของทุก clip — ซ้าย zero-shot, ขวา v5. สี = dataset, x = null.

- **Zero-shot:** TSL-ONE-S (ส้ม) กระจายเป็นแถบยาวแยกจาก TTRS (น้ำเงิน) ค่อนข้างมาก — encoder เดิมยังจำ "ลักษณะ dataset" (มุกกลิ้ง, extractor) ได้.
- **v5:** พื้นที่หดเป็นแกนกลางเดียว มีเกาะเล็กๆ จำนวนมากรอบนอก — แต่ละเกาะคือ concept หนึ่งคำที่หลายคนทำแล้วรวมกันได้ (โดยเฉพาะ TSL-ONE-S และ TSL51). TTRS เป็นก๊อปปี้กลางเพราะ 1 คน/1 คำ ไม่มีแรงดึงให้รวมกลุ่ม.
- **null (x)** อยู่เป็นกลุ่มย่อยไม่กี่จุด (rest pose, ท่าเริ่ม/จบ) ไม่ใช่จุดเดียว → เหตุผลที่ใช้ null gap เป็นแค่ feature หนึ่ง ไม่ใช่ตัวตัดสินเดียว.
- **ข้อควรระวัง:** UMAP รักษาความใกล้เคียงระดับเพื่อนบ้าน ไม่รักษาระยะไกล — ใช้ดู "การเกาะกลุ่ม" ได้ แต่ระยะระหว่างเกาะไม่มีความหมายเชิงปริมาณ (ตัวเลขจริงอยู่ §4–6).

4. การเกาะกลุ่มของคำ

4.1 คำเดียวกันจากหลาย dataset




Fig 2. 17 concepts ที่มี ≥ 3 clips ในอย่างน้อย 2 datasets (สุ่มไม่เกิน 12 clips ต่อ concept $\times$ dataset). marker = dataset.

- ทั้งสองแบบ concept ส่วนใหญ่เป็นเกาะแยกได้แล้ว (Uni-Sign pretrain ด้อยอยู่แล้ว) แต่ v5 ทำให้เกาะ **แน่นขึ้น** และ marker ต่าง dataset ซ้อนทับกันมากขึ้น (เช่น แม่, พี่, ชื้อ, ทำงาน).
- ย่า กับ ยาย ซ้อนกันทั้งก่อนและหลัง — lexicon แยกเป็นคนละ concept (ความหมายต่าง) แต่ทำมือนคล้ายกันมาก $\rightarrow$ latent space บอกตรงๆ ว่าคู่นี้ต้องใช้บริบท/ทำหน้าที่ช่วย ไม่ใช่ pose มืออย่างเดียว.
- โรงเรียน $\leftrightarrow$ เด็ก อยู่ใกล้กันใน v5 (ทำเริ่มคล้ายกัน) — เป็นตัวอย่างคู่ที่ต้องดู margin ตอน inference.

4.2 ความไม่ขึ้นกับคนทำ (signer invariance)




Fig 3. TSL-ONE-S 14 concepts สุ่ม $\times$ 29 signers. จุด = คน train/val, ★ = 5 คน test ที่โมเดลไม่เคยเห็น.

★ ของคนใหม่ตกลงในเกาะของคำที่ถูกต้องเกือบทั้งหมด ทั้ง zero-shot และ v5; ใน v5 เกาะหดแน่นกว่าและ ★ อยู่ตรงกลางเกาะ แทนที่จะอยู่ขอบ (เช่น ครอบครัว, ภรรยา, ณ).

4.3 ตัวเลขการเกาะกลุ่ม




Fig 4. การกระจาย cosine ของทุกคู่ใน TSL-ONE-S 2,000 clips.

ความสัมพันธ์ของคู่ clip	zero-shot mean (p10–p90)	v5 mean (p10–p90)
คำเดียวกัน · คนต่างกัน (ควรสูง)	0.60 (0.31–0.85)	0.70 (0.43–0.91)
คำต่างกัน · คนเดียวกัน (ควรต่ำ)	0.21 (0.07–0.37)	0.07 (–0.07–0.22)
คำต่างกัน · คนต่างกัน	0.19 (0.07–0.35)	0.06 (–0.08–0.21)

kNN-5 diagnostics (ทั้ง 11,622 clips)	zero-shot	v5
เพื่อนบ้าน 5 ตัวเป็นคำเดียวกัน	0.777	0.837
เป็นคนเดียวกัน	0.449	0.431
เป็น dataset เดียวกัน	0.936	0.951
เป็น extractor เดียวกัน	0.918	0.918

อ่านว่า: หลัง fine-tune คำต่างกันถูกผลักจนเกือบตั้งฉาก ($\cos \approx 0.06$) และ "คนเดียวกัน" แทบไม่ช่วยให้ใกล้เคียงอีก (0.065 vs 0.059) → **latent space ไม่ได้ปันตามตัวคน**. ส่วน same-dataset 0.95 ส่วนใหญ่มาจากว่าคำส่วนมากมีอยู่ใน dataset เดียว (ไม่ใช่ bias ล้วนๆ) — ดู cross-dataset check ใน §6.3.

4.4 ความแน่นของกลุ่ม vs ระยะเพื่อนบ้าน




Fig 5. 248 concepts ที่มี ≥ 3 instances ใน eval bank. แกน y = ความแน่น (cos เฉลี่ยของ instance กับ prototype ตัวเอง), แกน x = cos ของ prototype กับ prototype อื่นที่ใกล้สุด. เหนือเส้นประ = แยกได้.

	zero-shot	v5
median ความแน่น	0.80	0.87
median cos เพื่อนบ้านที่ใกล้สุด	0.75	0.66
concepts ที่อยู่เหนือเส้น (แน่นกว่าระยะเพื่อนบ้าน)	61 %	92 %

5. CosFace proxies

5.1 กลไก

ตอน training แต่ละ concept c (ที่มี ≥ 2 signers + `<null>`) มี proxy vector $\mathbf{w}_c$ (768-d, L2 norm) ใน matrix W ขนาด $4,571 \times 768$ (3.51 M params). $\text{logit} = s \cdot (\cos(z, \mathbf{w}_c) - m \cdot [c = y])$ ด้วย $s = 30$, $m = 0.25 \rightarrow$ clip ต้องใกล้ proxy ของคำตัวเองมากกว่า proxy คำอื่น อย่างน้อย **0.25 cos** จึงจะ loss ต่ำ.

- **Init:** $\mathbf{w}_c$ = mean ของ zero-shot embeddings ของ concept นั้น (ไม่ใช่สุ่ม) $\rightarrow$ เริ่มจากโครงที่ Uni-Sign มีอยู่แล้ว, gradient ช่วงแรกไม่ทำลาย pretrain.
- **ทำไมจำกัดเฉพาะ ≥ 2 signers:** concept ที่มีคนเดียว CosFace จะสอนให้จำ "คนนั้น+คำนั้น" (identity shortcut). concept พวกนี้ได้แค่ SupCon (ซึ่ง positive ต้องเป็น clip อื่น) + augmentation.
- **SupCon (0.5 $\times$):** ดึง clip คำเดียวกันใน batch เข้าหากันโดยตรง ($P=48$ concepts $\times K=2$ clips, 85 % เลือกคนต่างกัน) $\rightarrow$ เสริมส่วนที่ proxy ไม่ครอบคลุม.
- **ตอน inference ไม่ใช่ W เลย** ใช้ bank instances แทน (เพิ่มคำใหม่ได้ + รองรับ variant). proxies จึงเป็น "นั่งร้าน" ที่ปั้นรูปทรงพื้นที่เท่านั้น.
- **ข้อจำกัดของรายงาน (ตรงไปตรงมา):** W ที่ train แล้วถูกเก็บเฉพาะใน `ckpt_last.pt` ซึ่งลบไปแล้วตอน cleanup (เก็บแค่ encoder best step 400). ดังนั้นวิเคราะห์ W โดยตรงไม่ได้ — ใช้ **proxy ตอน init (= zero-shot class mean)** และ **class mean หลัง fine-tune ($\approx$ ตำแหน่งที่ proxy ถูกดึงไป)** เป็นตัวแทน. ถ้าต้องการ W จริงในอนาคต job_entry ต้อง export `proxies.npy` คู่กับ best checkpoint.

5.2 ผลที่เห็นในพื้นที่




Fig 6. ข้าย: query จากคน test ของ TSL-ONE-S — cos กับ prototype ที่ถูก (y) vs prototype ผิดที่ใกล้สุด (x); จุดเหนือเส้นประ = ได้ margin $\geq m$. กลาง: แต่ละ concept เคลื่อนจากตำแหน่ง init ไปแค่ไหน. ขวา: ระยะ prototype กับเพื่อนบ้านที่ใกล้สุด.

TSL-ONE-S held-out queries (873)	zero-shot	v5
mean cos กับ prototype ที่ถูก	0.76	0.79
mean cos กับ prototype ผิดที่ใกล้สุด	0.69	0.63
mean gap (ถูก - ผิด)	0.08	0.16
query ที่ได้ gap $\geq m = 0.25$	5 %	35 %
query ที่ gap > 0 (prototype-level top-1)	79 %	86 %

- CosFace ได้ผลหลักจาก **การผลักราคาผิดออก** ($0.69 \rightarrow 0.63$) มากกว่าการดึงค่าถูกเข้า ($0.76 \rightarrow 0.79$).
- margin 0.25 บน train ไม่ได้ generalize ครอบคลุมคนใหม่ (35 %) — เป็นเหตุผลที่ inference ใช้ z-score + margin + calibration แทน threshold ดายตัว.
- **Drift (กลาง):** concepts ที่อยู่ใน CosFace (≥ 2 signers) median cos(init, final) = 0.76 — เคลื่อนน้อยกว่าค่าคนเดียว (0.66). ดูกลับหัวแต่มีเหตุผล: ค่าหลายคนมี class mean ที่เสถียร ส่วนค่าคนเดียว mean = 1–2 clips ซึ่งขยับตาม augmentation/SupCon ทั้งก่อน.
- **Separation (ขวา):** nearest-other prototype median $0.73 \rightarrow \mathbf{0.66}$ (multi-signer), $0.69 \rightarrow 0.63$ (single) — ทั้งพื้นที่ "กว้างขึ้น".

5.3 มิติที่ใช้จริง




Fig 7. ซ้าย: cumulative explained variance ของ sign embeddings. ขวา: concept ที่เป็นคำตอบผิดพลาดที่สุด (hub) ของ held-out queries ใน v5.

- participation ratio 84 → **73** มิติ, 90 % variance ที่ 247 → **163** components: v5 บีบข้อมูลลงมิติน้อยลง (ทิ้งมิติที่เก็บ style/กล้อง) แต่ยังเหลือพื้นที่มากพอสำหรับ ~4.5k concepts.
- **Hubness:** error 576 ครั้ง ไปตกที่ 243 concepts; top-10 hubs เก็บ 24 % (zero-shot 21 %). hub เป็นคำที่ทำสั้น/เป็นกลาง (ไม่ใช่, ที่ไหน, ญ) หรือคำยาวที่ครอบคลุมหลายท่า (ย้ายจากกรุงเทพฯ ไปภาคตะวันตก, แต่งงานกันเถอะนะ) → เหมาะกับการทำ hubness correction (CSLS) หรือ down-weight ใน v6.

6. การดึงคำ (retrieval) และความแม่นยำ

6.1 Recall@k บน signer ที่ไม่เคยเห็น




Fig 8. Recall@k ต่อ protocol (เส้นประ = zero-shot, เส้นทึบ = v5), open vocabulary ≈ 4.5k concepts, eval bank.

protocol (open vocab)	n	R@1 zs → v5	R@5 zs → v5	R@10 v5	MRR zs → v5
TSL-ONE-S test signers	873	0.811 → 0.880	0.953 → 0.961	0.971	0.875 → 0.916
TTRS new signer (E1 test)	60	0.133 → 0.167	0.283 → 0.267	0.317	0.208 → 0.237
TSL51 researcher · MediaPipe	524	0.695 → 0.698	0.903 → 0.899	0.947	0.786 → 0.786
TSL51 researcher · RTMW	524	0.552 → 0.515	0.809 → 0.775	0.855	0.667 → 0.634
YouTube signers (E5)	14	0.286 → 0.357	0.500 → 0.429	0.571	0.398 → 0.417

ตัวเลขเพิ่มเติมจาก v5_isolated.json: TSL-ONE-S closed-184 0.850 → 0.893; TSL51 closed-set MP 0.905 / RTMW 0.861.

อ่านผล:

- เก่งมาก เมื่อ bank มีหลายคนต่อคำ (TSL-ONE-S): เกือบ 9/10 ถูกอันดับ 1, 96 % อยู่ใน 5 อันดับ.
- **TSL51 RTMW ลดลงเล็กน้อย** — encoder ถูกดึงไปทาง dataset ที่ใช้ MediaPipe (TSL-ONE-S/TSL51) และ RTMW ของ TSL51 เป็น pose ที่ไม่มีใน train (researcher เป็น held-out). pipeline จริงใช้ RTMW → นี่คือช่องว่างที่สำคัญที่สุดสำหรับวิดีโอจริง.
- **TTRS/YouTube ต่ำ** เพราะ bank มีคำนั้นแค่ 1 คน (ดู 6.2).

6.2 ความลึกของ bank = ตัวกำหนดความแม่นยำ




Fig 9. R@1 ของ held-out queries (รวม protocol, นับ clip researcher ครั้งเดียว) แยกตามจำนวน signers ของคำนั้นใน eval bank.

signers ของคำใน bank	n queries	R@1 zero-shot	R@1 v5
1	68	0.13	0.18
2	21	0.14	0.00
3-5	435	0.58	0.51
6-15	415	0.78	0.85
16+	532	0.80	0.88

ข้อสรุปที่สำคัญที่สุดของรายงาน: ความแม่นยำขึ้นกับ "มีคนทำคำนั้นใน bank กี่คน" มากกว่าตัว encoder. ≥ 6 คน $\rightarrow$ 85–88 %; 1–2 คน $\rightarrow$ < 20 %. ช่วง 3–5 คน (ส่วนใหญ่ TSL51 ที่ bank มีแค่ expert + web-scraped + ครู) v5 ลดลง 0.58 $\rightarrow$ 0.51 — encoder ไม่ได้แย่งโดยรวม แต่คำพวกนี้อยู่นอก CosFace/เห็น variant น้อย ทำให้ prototype ขยับไปทางที่ไม่ตรงกับ researcher. ทางแก้ที่คุ้มสุด: **เพิ่ม instance ของคนหลากหลายเข้า bank** (ไม่ต้อง train ใหม่) — deploy bank ทำไปบางส่วนแล้ว (+1,301 คำจากประโยค TSL51 + test/val clips).

6.3 ข้าม dataset / ข้าม extractor / null




Fig 10. ซ้าย: cos กับ null prototype ของ TSL51 researcher (เส้น = sign clips, แท่งทึบ = null_act clips 23 clips). ขวา: cos ระหว่าง pose MediaPipe กับ RTMW ของวิดีโอเดียวกัน (524 คู่).

	zero-shot	v5
null vs sign AUC (MP / RTMW)	0.83 / 0.86	0.89 / 0.90
cos กับ null: sign clips (MP / RTMW)	0.28 / 0.24	0.07 / 0.04
cos กับ null: null clips (MP / RTMW)	0.44 / 0.41	0.43 / 0.45
วิดีโอเดียวกัน MP ↔ RTMW (median)	0.81	0.84
ค่าเดียวกัน คนละวิดีโอ MP ↔ RTMW	0.75	0.76
คู่สุ่ม	0.15	0.06

- null แยกได้ดีขึ้นเพราะ sign clips ถูกผลักออกจาก null ($0.28 \rightarrow 0.07$) ในขณะที่ null clips อยู่เดิม; null_act ของ TSL51 กระจายกว้าง (0–1) เพราะ "ท่าไม้ไผ่คำ" มีหลายแบบ.
- extractor gap: คู่ MP↔RTMW วิดีโอเดียวกันได้ 0.84 $\approx$ ระดับเดียวกับ "ค่าเดียวกันคนละคน" $\rightarrow$ ต่าง extractor เท่ากับ เปลี่ยนคนทำหนึ่งคน. ยอมรับได้แต่ยังเป็นแหล่ง error.

Cross-dataset prototype check (vocab/v5/cross_dataset_check.csv): TSL-ONE-S $\rightarrow$ TTRS top-1 0.80 / top-5 0.96 (n 139); TSL51 $\rightarrow$ TTRS 0.73 / 1.00 (n 45); YouTube $\rightarrow$ TTRS 0.32 $\rightarrow$ การรวม gloss จากหลาย dataset เป็น concept เดียวกันยังได้ด้วย latent space เองสำหรับ 2 datasets หลัก.

7. Inference: การดึงคำจาก bank ทีละขั้น

สำหรับแต่ละ window w (ยาว 8–48 frames, stride 2) ภายใน region ที่ tagger บอกว่าเป็นท่า:

1. $q = \text{encoder}(\text{window}) \rightarrow 768\text{-d unit vector}$
2. $\cos(q, \text{ทุก instance ใน deploy bank } 12,843) \text{ — matrix product เดียวบน GPU}$
3. $\text{score}(c) = \text{mean ของ 2 instance ที่ใกล้สุดของ concept } c \text{ (ถ้ามี instance เดียวใช้นั้น)}$ — ทนต่อ outlier และรองรับหลาย variant
4. $z = (\text{top1} - \text{mean}(\text{scores})) / \text{std}(\text{scores})$; $\text{margin} = \text{top1} - \text{top2}$; $\text{null_gap} = \cos(q, \text{null}) - \text{top1}$
5. DP เลือก window ที่ไม่ทับกันด้วย $\text{gain} = z - \lambda - \mu \cdot \max(0, \text{null} - \text{top1}) + \beta \cdot P_{\text{begin}}$

Fig 11. top-6 concepts ต่อ segment; เขียว = คำอ้างอิงของทวีตนั้น.




Fig 13. cosine ระหว่าง prototype (deploy bank) ของคำอ้างอิง data_test (ซ้ายบน) กับคำตอบผิดที่พบ (ขวาล่าง). แสดงตัวเลขเมื่อ > 0.5 .

9. ข้อสรุปและสิ่งที่ควรทำต่อ

สภาพของ latent space v5

1. เป็นพื้นที่ที่ตี: ค่าเดียวกันจากคนต่างกันรวมกลุ่ม ($\cos 0.70$), ค่าต่างกันเกือบตั้งฉาก (0.06), ไม่ปนตามคนทำ, null แยกได้ AUC 0.89–0.90.
2. CosFace + SupCon เพิ่ม margin จริง (gap $0.08 \rightarrow 0.16$, query ที่ได้ margin $\geq m$ $5 \rightarrow 35\%$) และขยายระยะระหว่าง prototype.
3. ความแม่นยำในทางปฏิบัติถูกจำกัดโดย **ความลึกของ bank** ($1-2$ คน $\rightarrow < 20\%$, ≥ 6 คน $\rightarrow 85-88\%$), **extractor gap (RTMW)** และ **query** ที่หลุดเกาะจากการทำหาคู่ต่อเนื่อง.

ข้อเสนอ (เรียงตามความคัม)

- เพิ่ม instance เข้า deploy bank สำหรับคำที่ใช้บ่อยแต่มี < 3 คน (ร้องไห้, รัก, ปลอบใจ, ตี๋ม, ปรบมือ ...) — ไม่ต้อง train ใหม่

- ทำ bank แบบคู่ extractor: embed clip MediaPipe ด้วย RTMW pose ของวิดีโอเดียวกันเมื่อมีวิดีโอติด (TSL51 ทำแล้ว) เพื่อลด gap 0.84.
- hubness correction (CSLS: ลบค่าเฉลี่ยความใกล้เคียงของ concept กับ query ทั่วไป) สำหรับ hub 10 ตัวที่กิน error 24 %.
- บันทึก CosFace proxy matrix W คู่กับ best checkpoint ใน job ต่อไป เพื่อวิเคราะห์ proxy จริงและใช้เป็น prior สำหรับค่าที่ bank บาง.
- เพิ่ม fast/co-articulated sign augmentation (window ที่ตัดจากประโยค) เพื่อให้ query จากวิดีโอจริงตกในเกาะ.

Appendix — ไฟล์และการ reproduce

item	path
script	scripts/v5_latent_report.py (ใช้ GPU เฉพาะ 8)
statistics	artifacts/reports/v5_latent_report.json
figures	result_reporting/latent_v5/f1...f13_*.png
embeddings	artifacts/v5/runs/train_all-20260914-170615-europe-west4/emb_v5.npy , emb_zero_shot.npy , emb_index.parquet , concept_index.json
banks	artifacts/v5/model/bank_eval.npz , bank_deploy.npz , null_proto.npy
rendering	python scripts/md_to_pdf.py result_reporting/latent_report_v5.md

Metric definitions: R@k = สัดส่วน query ที่ concept ถูกอยู่ใน k อันดับแรกของ concept scores (top-2 instance mean) โดยตัด <null> ออก; MRR = ค่าเฉลี่ย 1/rank; prototype = L2-normalised mean ของ instances ของ concept ใน bank; participation ratio = $(\sum \lambda)^2 / \sum \lambda^2$ ของ covariance eigenvalues; kNN diagnostics จาก v5_isolated.json .