ThaiSLM — Result Report v8.1 (Forward: Sign → Text)

Scope (prompt_12): ปิด GAP ที่เหลือจาก v8 โดยโฟกัส **recognize + generalize** (ไม่โฟกัส grammar/เว็บ/reverse) — (1) ทายผิดคำที่คล้ายกัน (ฉัน/ชอบ, ซื่อ/เพื่อน), (2) grammar ทับคำที่ท่าบอกถูก, (3) ท่าลื่นต่อเนื่องตัดไม่ได้, (4) คำถูกแต่ P ต่ำ, (5) guard คำซ้ำ, (7) จีน / ประเทศ "OOV" + สะกดนิ้วต้องกดเปิดเอง. ฐานเริ่มต้น = v8 (prompt_11). Encoder / tagger / span head / bank **ไม่ได้เทรนใหม่** — ทุกอย่างเป็น CPU บนเครื่อง (**$0**). ทุกค่าเลือกบนชุด **tune** เท่านั้น; ชุด test, data_test/ และ iphone_test/ **ไม่ถูกใช้เลือกอะไรเลย** (iPhone = ชุดดูอย่างเดียว ตามที่ตกลง). Lab: `lab2.ipynb` → **2. After Tuning** · โค้ด: `modules/handshape.py` (ใหม่), `modules/pipeline.py`, `modules/decode.py`, `scripts/decision.py`.

---

0. TL;DR

คำถาม	คำตอบ
ทายคำถูกมากขึ้นจริงไหม (GAP 1)?	**ใช่ ชัดเจน ทุกชุด test** — TSL51 test Recall@1 1× **0.609** → **0.700**, 2× 0.560 → **0.638**; คำเดี่ยวของคนที่ระบบไม่เคยเห็น 0.766 → **0.801**; macro-F1 TSL51 0.66 → **0.79**
WER (ไม่เคยใช้เลือกค่า)	TSL51 1× / 1.5× / 2×: 0.394 / 0.364 / 0.376 → **0.309 / 0.284 / 0.292** (ผลต่าง −0.08, 95% CI ไม่คร่อม 0 ทุกความเร็ว) · คำเดี่ยว 0.295 → **0.253** · ประโยคลื่น 0.448 → **0.397** (regression ของ v8 หายไป และดีกว่า v7.2 ด้วย)
วิดีโอจริง (ดูอย่างเดียว)	iPhone ประโยค WER 0.283 → **0.126** · iPhone คำ 0.444 → **0.222** (Recall@1 0.75 → **1.00**: ซื่อ ✓ ชอบ ✓) · data_test 0.752 → **0.684**
"พรุ่งนี้ฉันไปเที่ยวประเทศจีน"	v8: ถูก 2/6 (ประเทศ→กรุงเทพ, จีน→แต่งงาน) → **v8.1: ถูก 6/6 จำนวนท่าถูกพอดี**
จีน / ประเทศ "OOV"?	**ไม่ใช่ OOV** — มีใน bank 24 คน/คำ (TSL-ONE-S) แต่ vocab สนทนา 326 คำไม่ได้ใส่ไว้ → เพิ่มแล้ว (ต้นทุนบน tune = 0)
สะกดนิ้วต้องกดเปิด?	**ไม่ต้องแล้ว** — ตัวอักษรอังกฤษอ่านทุก utterance อัตโนมัติ (`"alphabet": "en"`). iPhone "...ภาษามือ **A I**" → A (P 1.00), I (0.99). บน tune: แทรกตัวอักษรผิด **0** ครั้งใน 783 utterance
ความมั่นใจ (Accept) ยังแม่นไหม	accepted precision ทุกชุด test ≥ **0.953** (เป้า 0.90); คำถูกที่ถูก Reject ลดลงมาก (TSL51 2×: 77 → **9** segment ที่ Reject)
แย่ลงตรงไหน (ตรงๆ)	ECE แย่กว่า v8 เล็กน้อย (TSL51 1× 0.042 → 0.060; ยังดีกว่า v7.2 0.107) · คำที่ Accept ได้ถูกบน TSL51 1.5×/2× ลดลง (135→125, 130→122) · count error TSL51 1× 0.286→0.349, คำเดี่ยว 0.083→0.088, data_test 0.6→1.0 · J ตัวเดียวกลางประโยคยังไม่ขึ้น · latency +75 ms/คลิป — §6
Cost	**$0** — ไม่ใช้ GPU/Vertex/Cloud Storage เลย (ตรวจแล้ว: 0 job ทั้ง 3 region, bucket ว่าง, ไม่มี VM/disk)

ตารางสรุปเทียบกับทีม — v7.2 · v8 · v8.1 (Forward, conversation vocabulary)

ทุกค่ามาจาก run เดียวกัน (`python main.py decision report` → `artifacts/reports/decision_v8.1.json`): โค้ดและ cache เดียวกัน ต่างแค่การตั้งค่าที่แต่ละเวอร์ชัน ship (v7.2 = git `f08a56d`, v8 = `artifacts/baselines/v8/`, v8.1 = `models/`). ชุด test ไม่เคยใช้เลือกค่า · วิดีโอจริง (data_test, iPhone) = ดูอย่างเดียว. **ตัวหนา** = ดีที่สุดของชุดนั้น.

ชุด (n)	model	WER ↓	Segment F1 ↑	Recall@1 ↑	Recall@5 ↑	Accepted words correct	Accepted precision ↑	Count error ↓	Latency (model, ms/clip) ↓
TSL51 test 1× (126)	v7.2	0.432	0.854	0.600	0.791	64 / 78	0.821	0.405	–
	v8	0.394	0.874	0.609	0.793	92 / 95	0.968	**0.286**	–
	v8.1	**0.309**	**0.880**	**0.700**	**0.847**	**97 / 99**	**0.980**	0.349	–
TSL51 test 1.5× (126)	v7.2	0.374	0.863	0.600	0.771	74 / 81	0.914	**0.317**	–
	v8	0.364	**0.868**	0.600	0.769	**135 / 136**	**0.993**	0.341	–
	v8.1	**0.284**	0.866	**0.676**	**0.804**	125 / 128	0.977	0.325	–
TSL51 test 2× (126)	v7.2	0.386	0.805	0.560	0.698	72 / 78	0.923	0.556	–
	v8	0.376	0.805	0.560	0.696	**130 / 134**	**0.970**	0.563	–
	v8.1	**0.292**	**0.818**	**0.638**	**0.733**	122 / 128	0.953	**0.524**	–
คำเดี่ยว คนที่ไม่เคยเห็น (217)	v7.2	0.392	0.913	0.743	**0.925**	50 / 52	0.962	0.171	–
	v8	0.295	**0.951**	0.766	**0.925**	72 / 74	0.973	**0.083**	–
	v8.1	**0.253**	0.949	**0.801**	0.917	**77 / 78**	**0.987**	0.088	–
ประโยคลื่นสังเคราะห์ (120)	v7.2	0.435	**0.943**	0.589	0.810	64 / 65	0.985	0.417	–
	v8	0.448	0.936	0.562	0.793	101 / 105	0.962	0.467	–
	v8.1	**0.397**	**0.943**	**0.628**	**0.839**	**102 / 103**	**0.990**	**0.392**	–
data_test (5)	v7.2	0.752	–	0.500	**0.850**	2 / 2	1.000	**0.600**	**530**
	v8	0.752	–	0.500	**0.850**	2 / 2	1.000	**0.600**	546
	v8.1	**0.684**	–	**0.524**	0.762	2 / 2	1.000	1.000	621
iPhone คำ (9)	v7.2	0.444	–	0.750	**1.000**	2 / 2	1.000	**0.111**	(รวมในแถว data_test)
	v8	0.444	–	0.750	**1.000**	**3 / 3**	1.000	**0.111**	
	v8.1	**0.222**	–	**1.000**	**1.000**	2 / 2	1.000	0.222	
iPhone ประโยค (5)	v7.2	0.311	–	0.875	**0.958**	3 / 3	1.000	0.400	
	v8	0.283	–	0.875	**0.958**	4 / 4	1.000	**0.200**	
	v8.1	**0.126**	–	**0.885**	0.923	**6 / 6**	1.000	**0.200**	

Latency (CPU laptop, ONNX Runtime, วัดบนวิดีโอจริงทั้ง 19 คลิป ความยาวเฉลี่ย 7.3 s, ไม่รวม MediaPipe):

model	ms ต่อคลิป ↓	ms ต่อวินาทีวิดีโอ ↓	Memory (RSS)	MediaPipe Holistic
v7.2	**530**	**72**	719 MB	28 ms/เฟรม (ทุกเวอร์ชันเท่ากัน; ฝั่งเว็บรันในเบราว์เซอร์)
v8	546	74	725 MB	
v8.1	621 (+14% จาก v8: hand cue + สะกดนิ้วอัตโนมัติ)	85	726 MB	

นิยามตัววัด (เหมือน result_v8 §1.2 — เทียบกับรายงานเดิมได้ตรงๆ)

- **WER** = (แทน + หาย + เกิน) / จำนวนคำเฉลย บน top-1 ของทุก sign segment (ไม่นับ transition; ตัวอักษรสะกดนิ้วนับเป็นคำ) — เหมือน `pitty/scripts/sentence_eval.py`
- **Segment F1** = จับคู่ segment กับขอบเขตเฉลยที่ IoU ≥ 0.3 (TSL51 = forced alignment, คำเดี่ยว = span ของคลิป, ประโยคลื่น = ขอบเขตที่ต่อเอง) — วิดีโอจริงไม่มีขอบเขต → "–"
- **Recall@1 / @5** = คำเฉลย (ที่อยู่ใน vocabulary ของเวอร์ชันนั้น) ที่ segment ที่จับคู่ได้มี top-1 / top-5 ถูก · วิดีโอจริง = มีคำนั้นใน top-1 / top-5 ของ segment ใดก็ได้
- **Accepted words correct** = คำสถานะ Accept ที่ถูก / Accept ทั้งหมด (คำที่ระบบ "ยืนยัน") · **Accepted precision** = อัตราส่วนเดียวกันเป็นทศนิยม
- **Count error** = |จำนวน segment − จำนวนคำเฉลย| เฉลี่ยต่อประโยค/คลิป
- วิดีโอจริงมีตัวอย่างน้อย (5 / 9 / 5 คลิป) — ต่างกัน 1 คลิปเปลี่ยนตัวเลขมาก ใช้ดูแนวโน้ม ไม่ใช้สรุปทั่วไป; ช่วงความเชื่อมั่นของผลต่างอยู่ใน §3.2

---

1. Diagnosis — ทำไมยังทายผิด (ก่อนแก้)

ตรวจจาก bank (`models/bank.npz`), embedding ของ clip คนที่ไม่เคยเห็น (val/test role) และวิดีโอ iPhone:

สาเหตุ	หลักฐาน	ผล
Bank coverage (สาเหตุใหญ่ของคำที่ผิดทุกครั้ง)	82 / 326 คำสนทนามี **คนทำท่าแค่ 1 คน**; อยาก, นำเสนอ, งาน, ถูก มี **1 คลิป**	แก้ด้วยข้อมูลเท่านั้น → รายการเก็บเพิ่ม §7
Embedding แยกคำคล้ายกันไม่ออก (ฉัน/ชอบ, ชื่อ/เพื่อน)	encoder ให้คำถูกใน top-5 (R@5 0.79) แต่ไม่ขึ้นที่ 1; การให้คะแนนแบบอื่นบน embedding เดิม (top-1, centroid, signer-max, WCCN, NAP, Z-norm) **ไม่ช่วย** (±1 pt)	ต้องมี **หลักฐานใหม่** ที่ encoder ไม่มี → hand-shape cue §2.1
Vocabulary ตัดคำที่มีข้อมูลดีทิ้ง	จีน / ประเทศ 24 คน/คำ แต่ไม่อยู่ใน 326 คำ; ท่าแบบอื่นของคำเดียวกัน (สวัสดี "อายุเท่ากันหรือน้อยกว่า", ภาษามือโรงเรียนเศรษฐเสถียร / ราชสุดา) ถูกเก็บเป็นคนละคำ 61 แบบ	เพิ่มคำ + รวมท่าแบบอื่นเข้าคำเดิม §2.3
Grammar re-rank ทับคำ	หลัง ranking ใหม่ กฎเดิมวัด "ระยะห่างทางภาพ" ด้วย `score` ไม่ใช่ค่าที่ใช้จัดอันดับ → เปลี่ยนคำได้แทบฟรี; และทำงานกับคลิปท่าเดียวด้วย	guard §2.4
Segmentation ท่าลื่น	ประโยคเร็ว/ลื่น segment น้อยกว่าคำจริง (TSL51 2× 385 vs 450 คำ, ประโยคลื่น −7%) = 2 ท่ากลายเป็น 1	split test §2.2
Domain shift / segmentation error	คำถูกบางคำยังได้ P ต่ำ (ไป) เพราะท่าของผู้ทดสอบต่างจาก reference	calibration ใหม่ + ข้อมูล

---

2. ทำอะไร (เลือกบน **tune** ทุกข้อ; เกณฑ์ v8: ไม่มีชุด **tune** ไหนแย่ลงเกิน **0.003 WER** และต้องดีขึ้น > **0.002**)

2.1 Hand-shape cue — หลักฐานอิสระจากรูปมือ (`modules/handshape.py`)

ทุก segment ถูกอธิบายตรงจาก landmark: มุมงอของแต่ละข้อนิ้ว (15), ระยะปลายนิ้ว–ข้อมือ / ปลายนิ้วโป้ง–นิ้วอื่น, ทิศฝ่ามือ, ตำแหน่งมือเทียบไหล่และจมูก, การเคลื่อนที่ใน 3 ช่วงเวลาของท่า, ความสัมพันธ์สองมือ → เทียบกับคำอธิบายเดียวกันของทุกคลิปใน bank ผ่าน metric (standardise + shrinkage LDA) ที่ฟิตจาก **คนใน train เท่านั้น** (`python main.py decision hands`). แล้วรวมกับการอ่านของ encoder บน **ทั้ง segment** (span head, ทุกคำใน vocabulary): `fused = z(encoder) + w·z(hand)`.

หลักฐาน	ผล
Probe (คลิปคนที่ไม่เคยเห็น vs bank คน train)	hand cue อย่างเดียว R@1 0.66; รวมกับ encoder: test 0.735 → 0.772 (คน TSL51 0.687 → 0.771, YouTube +6 pt)
Tune (ทั้ง chain) — สแกน w	WER เฉลี่ย 5 ชุด tune 0.432 (v8) → 0.410 (w 0.4) → 0.400 (0.8) → **0.391 (w = 1.2 เลือก)** · 1.5 ดีกว่าแค่ 0.0016 (< 0.002) · 2.0 แย่ลง
ผลที่ตั้งใจแก้	iPhone คำ: ซื่อ (v8 = เพื่อน) ✓, ชอบ (v8 = ฉัน) ✓

2.2 Segmentation

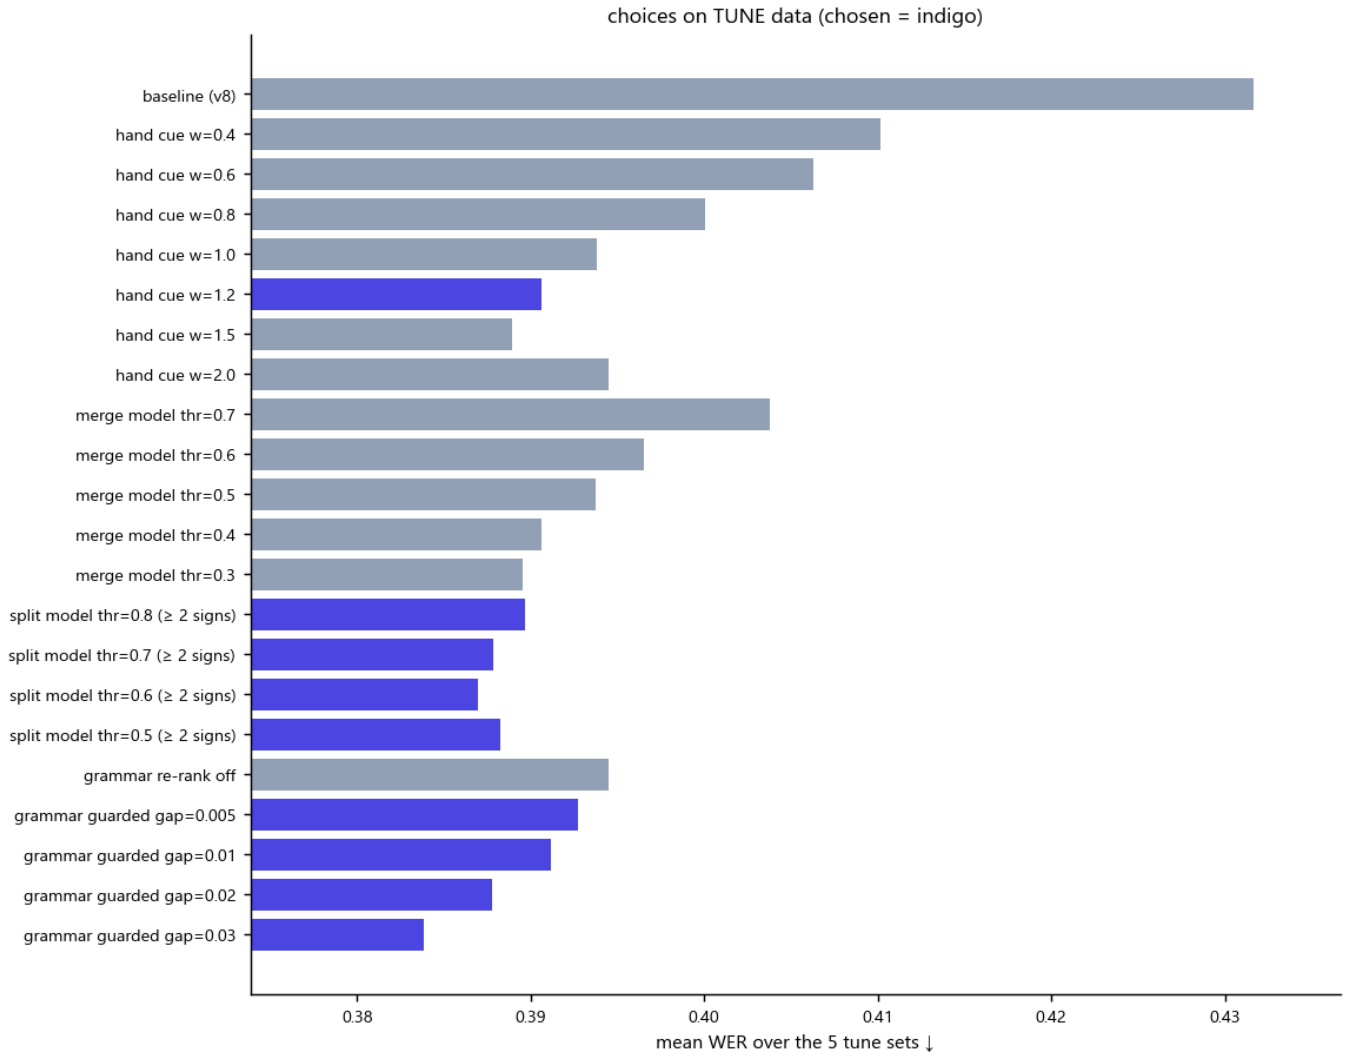
สิ่งที่ทำ	ผลบน tune	สถานะ
Split test (`decode.split_long`, กลับด้านของ merge ของ v8): segment ยาวลองตัด 3 จุดที่มีหลักฐานรอยต่อมากที่สุด (tagger begin/rest, ความเร็วมือ) → อ่านสองครึ่ง vs ทั้งก้อน → logistic P(สองท่า) (11 feature, 3,735 จุดตัด, CV AUC **0.81**)	ไม่มี guard: ช่วยท่าเร็ว แต่ตัดคำเดี่ยวผิด (iso +0.012) → ไม่ผ่าน · **ใช้เฉพาะ utterance ที่มี ≥ 2 ท่า**: TSL51 2× 0.320 → 0.315, ประโยคลื่น R@1 0.470 → 0.485, คำเดี่ยวไม่เปลี่ยน	✅ thr 0.7
Merge model (v8) ฟิตใหม่บน readings ใหม่	thr 0.4 เดิมยังดีที่สุด (0.3 ดีกว่าแค่ 0.001)	คงเดิม

2.3 Vocabulary + bank

สิ่งที่ทำ	ผล
+ จีน, ประเทศ (`vocab/daily_conversation.json` หมวด `travel`)	ต้นทุนบน tune = 0.000 ทุกชุด
ทดลองเพิ่มคำที่มีคนทำ ≥ 6 คน 108 คำ (TSL-ONE-S: กีฬา สถานที่ ประเทศ)	**ไม่ใช่** — R@1 TSL51 tune −9 pt: บางคำเป็น "แม่เหล็ก" ในประโยคจริง (แฟนสาว 55 ครั้ง, อิสราเอล 40, กะเทย 37 ...); กรองเหลือ 29–53 คำก็ยังเสีย +0.004–0.006 → รอข้อมูลมากขึ้น
รวมท่าแบบอื่นของคำเดียวกัน (61 แบบ: ภาษามือโรงเรียน/วิทยาลัย, สวัสดี/ขอบคุณ/ขอโทษ แบบ "อายุเท่ากันหรือน้อยกว่า") → `vocab_conversation.json` `variants`, รวมตอนโหลด bank (ไฟล์ bank ไม่เปลี่ยน)	WER tune เฉลี่ย 0.443 → 0.432 · 13 คำที่มี 1 คน (จำ, รู้, สอน, ใคร, ใช่, ใหม่ ...) ได้ตัวอย่างที่ 2

2.4 Decision layer

สิ่งที่ทำ	ผลบน tune	สถานะ
Grammar re-rank มี guard: ไม่ใช้กับคลิป 1 ท่า, วัดระยะด้วยค่าที่ใช้จัดอันดับจริง (`support`), จำกัดระยะ (0.005–0.03)	ปิด grammar: 0.3945 · guard gap 0.03: **0.3839** (ดีกว่าปิด 0.011 > 0.005 ตามกฎ v7) · ดีกว่า grammar เดิมไม่มี guard (TSL51 1× 0.303 → 0.284)	✅ (หมายเหตุ: tune เป็นประโยค TSL51 จึงได้เปรียบเรื่องลำดับคำ — guard ทำให้ไม่ทับคำที่ท่าบอกชัด)
Re-ranker top-5 ของ v8 (ไม่ผ่านใน v8: +0.6 pt)	CV top-1 0.768 → **0.782** (+1.4 pt ≥ เกณฑ์ 1 pt)	✅ ใช้
Repeat guard: occurrence ที่ P ≥ 0.8 ไม่ถูกลดสถานะ (คำซ้ำในประโยคเป็นเรื่องปกติ)	WER เท่าเดิมทุกชุด; 0.6/0.5 ทำให้ประโยคลื่น +0.004 → เลือก 0.8	✅ ("ฉัน" ตัวที่ 2 ใน 3302 ไม่ถูก Reject แล้ว)
Calibration: temperature + logistic P(correct) ฟิตใหม่บน readings ใหม่; เทียบ feature set	v8 features CV log-loss **0.4584** (เลือก) · + hand cue 0.4592 · + dec-agree/split/rerank flags 0.4567 (ต่างน้อยกว่า noise → ไม่ใช้)	T = 0.086
Threshold (accepted precision ≥ 0.90 ทุกชุด tune)	τ_accept **0.92** (global = +margin = +ความยาว ได้ค่าเท่ากัน), τ_reject **0.15** (กลุ่ม Reject ผิดจริง ≥ 85%)	✅
สะกดนิ้วอัตโนมัติ (`"alphabet": "en"`): เลือก thr / single_min / run_min โดยห้ามมีตัวอักษรแทรกในทุก utterance ของ tune (783) แล้วอ่านตัวอักษรใน lesson ได้มากสุด	false letters **0** · อ่านตัวอักษร: lesson train 0.605, **channel ที่ไม่เคยเห็น 0.643** · ตัวอักษรเดี่ยวต้อง P ≥ 0.98	✅ · ภาษาไทย ก–ฮ **ไม่เปิดอัตโนมัติ**: แทรกผิด 5–14% ของคำบนคลิปคำ (ท่ามือตัวอักษรไทยคล้ายท่าคำ)



3. ผลบน test (ไม่เคยใช้เลือกค่า) + วิดีโอจริง

Bank สำหรับ test = คน train เท่านั้น (`artifacts/eval/bank_eval.npz` + `hand_bank_eval.npz`); วิดีโอจริงใช้ `models/` . ทั้ง 3 เวอร์ชันรันด้วยโค้ดและ cache เดียวกัน ต่างแค่การตั้งค่าที่ ship (`python main.py decision report`): v7.2 = git `f08a56d` , v8 = `artifacts/baselines/v8/` , v8.1 = `models/` — แต่ละเวอร์ชันใช้ vocabulary ของตัวเอง.

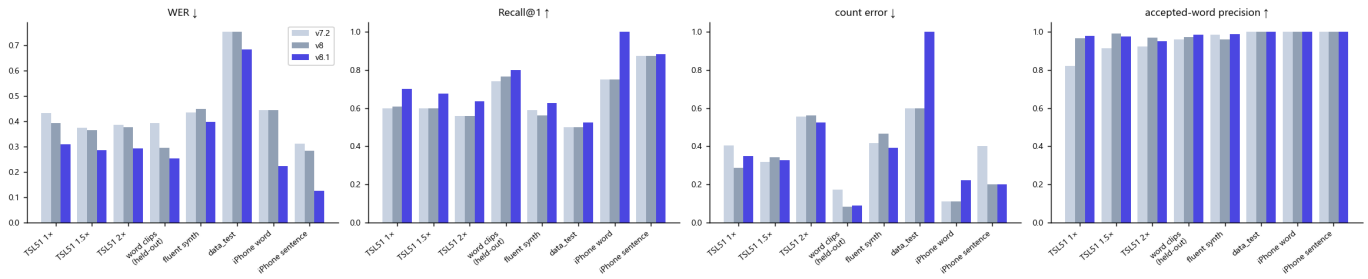
3.1 ตารางหลัก

ชุด (n)	version	WER ↓	Recall@1 ↑	Recall@5 ↑	macro-F1 ↑	Seg F1 ↑	Count err ↓	Accepted ถูก/ทั้งหมด	Acc. prec ↑
TSL51 1× (126)	v7.2	0.432	0.600	0.791	0.661	0.854	0.405	64/78	0.821
	v8	0.394	0.609	0.793	0.663	0.874	**0.286**	92/95	0.968
	v8.1	**0.309**	**0.700**	**0.847**	**0.787**	**0.880**	0.349	**97/99**	**0.980**
TSL51 1.5×	v7.2	0.374	0.600	0.771	0.707	0.863	**0.317**	74/81	0.914
	v8	0.364	0.600	0.769	0.708	**0.868**	0.341	**135/136**	**0.993**
	v8.1	**0.284**	**0.676**	**0.804**	**0.788**	0.866	0.325	125/128	0.977
TSL51 2×	v7.2	0.386	0.560	0.698	0.695	0.805	0.556	72/78	0.923
	v8	0.376	0.560	0.696	0.695	0.805	0.563	**130/134**	**0.970**
	v8.1	**0.292**	**0.638**	**0.733**	**0.799**	**0.818**	**0.524**	122/128	0.953
คำเดี่ยว คนที่ไม่เคยเห็น (217)	v7.2	0.392	0.743	**0.925**	0.626	0.913	0.171	50/52	0.962
	v8	0.295	0.766	**0.925**	0.636	**0.951**	**0.083**	72/74	0.973
	v8.1	**0.253**	**0.801**	0.917	**0.710**	0.949	0.088	**77/78**	**0.987**
ประโยคลิ่นสังเคราะห์ (120)	v7.2	0.435	0.589	0.810	0.508	**0.943**	0.417	64/65	0.985
	v8	0.448	0.562	0.793	0.499	0.936	0.467	101/105	0.962
	v8.1	**0.397**	**0.628**	**0.839**	**0.596**	**0.943**	**0.392**	**102/103**	**0.990**
data_test (5)	v7.2 / v8	0.752	0.500	0.850	–	–	**0.600**	2/2	1.000
	v8.1	**0.684**	**0.524**	0.762	–	–	1.000	2/2	1.000
iPhone คำ (9)	v7.2 / v8	0.444	0.750	1.000	–	–	**0.111**	2/2 · 3/3	1.000
	v8.1	**0.222**	**1.000**	1.000	–	–	0.222	2/2	1.000
iPhone ประโยค (5)	v7.2	0.311	0.875	**0.958**	–	–	0.400	3/3	1.000
	v8	0.283	0.875	**0.958**	–	–	**0.200**	4/4	1.000
	v8.1	**0.126**	**0.885**	0.923	–	–	**0.200**	**6/6**	1.000

3.2 Paired bootstrap (10,000 resamples, ตัวอย่างเดียวกัน) — ΔWER

ชุด	v8.1 − v8 [95% CI]	ดีขึ้น / แย่ลง (utterance)	v8.1 − v7.2 [95% CI]
TSL51 1×	**−0.085** [−0.118, −0.051]	42 / 10	−0.123 [−0.161, −0.086]
TSL51 1.5×	**−0.079** [−0.112, −0.048]	40 / 8	−0.089 [−0.122, −0.058]
TSL51 2×	**−0.084** [−0.116, −0.054]	38 / 6	−0.094 [−0.126, −0.063]
คำเดี่ยว	−0.041 [−0.083, 0.000]	14 / 5	−0.138 [−0.198, −0.083]
ประโยคลื่น	**−0.051** [−0.085, −0.018]	36 / 15	−0.038 [−0.070, −0.005]
data_test / iPhone คำ / iPhone ประโยค	−0.069 / −0.222 / −0.157	2/0 · 2/0 · 2/0	n เล็กเกินกว่าจะสรุปทั่วไปได้

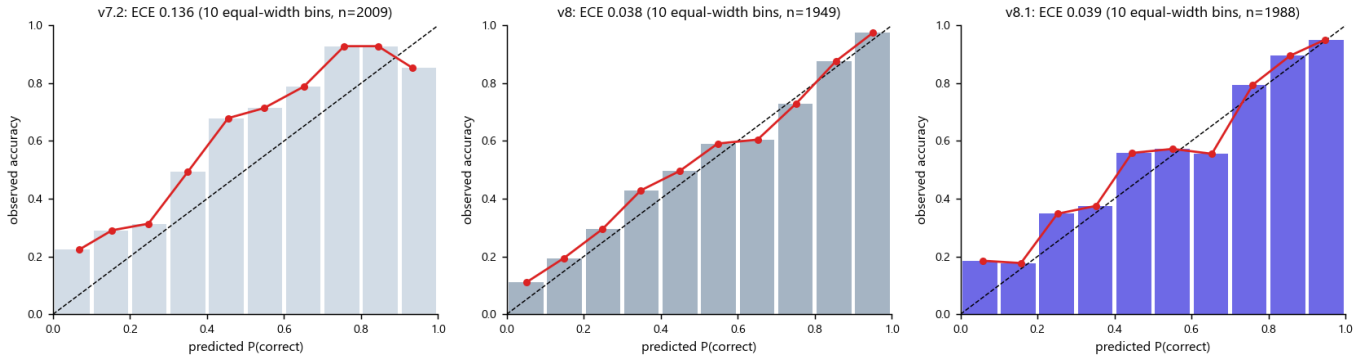
ต่อคน: คำเดี่ยว (13 คน) ดีขึ้น 6 คน, **แย่ลง 0**, เท่าเดิม 7 · ประโยคลื่น (8 คน) ดีขึ้น 5, แย่ลง 3 (S_one_02 0.32 → 0.37, S_one_17 0.35 → 0.36, S_one_23 0.28 → 0.28).



3.3 ความมั่นใจ (Accept / Uncertain / Reject)

ชุด	ECE v7.2 / v8 / v8.1	Brier v8 / v8.1	False-accept rate v8 / v8.1	คำถูกที่ถูก Reject v8 / v8.1	P เฉลี่ยของคำถูก v8 / v8.1
TSL51 1×	0.107 / **0.042** / 0.060	**0.138** / 0.148	0.016 / **0.013**	7.7% / **0.6%**	0.74 / **0.76**
TSL51 1.5×	0.147 / **0.043** / 0.070	**0.121** / 0.134	**0.007** / 0.025	6.3% / **0.0%**	0.78 / **0.79**
TSL51 2×	0.141 / 0.051 / **0.030**	**0.134** / 0.142	**0.030** / 0.056	5.2% / **0.3%**	0.79 / 0.79
คำเดี่ยว	0.116 / **0.047** / 0.061	**0.151** / 0.164	0.028 / **0.016**	6.1% / **2.3%**	0.77 / **0.79**
ประโยคลื่น	0.178 / **0.028** / 0.048	0.160 / **0.157**	0.022 / **0.006**	6.7% / **2.0%**	0.72 / **0.74**
iPhone คำ / ประโยค	–	0.178 / **0.111** · 0.130 / 0.131	0 / 0	16.7% / **0%** · 19.0% / **4.0%**	0.69 / **0.73** · 0.67 / **0.73**

ECE = 10 ช่วงกว้างเท่ากัน (equal-width bins) ของ P(correct) รวมทุก segment ที่ไม่ใช่ transition ของชุดนั้น (n ≈ 230–470 ต่อชุด).



4. iPhone (data_test/iphone_test) — ก่อน/หลัง (ดูอย่างเดียว ไม่ได้ใช้จูน)

`คำ` = Accept · `คำ?` = Uncertain ("อาจหมายถึง") · `X` = Reject · (P(correct))

คลิป	เฉลย	v8	v8.1
คำ 3293 / 3295	สวัสดี	สวัสดี? (0.39) / สวัสดี? (0.72)	สวัสดี? (**0.53**) / สวัสดี? (**0.81**)
คำ 3296	ฉัน	ฉัน (0.95)	ฉัน (0.94)
คำ 3297	ชื่อ	**เพื่อน?** (0.49) ยายX	**ซื่อ?** (0.62) ย่าX
คำ 3298	ชอบ	**ฉัน?** (0.67)	**ชอบ?** (0.81)
คำ 3299	แมว	แมว (0.97)	แมว (0.98)
คำ 3308	พรุ่งนี้	พรุ่งนี้ (0.90)	พรุ่งนี้? (0.90 < τ 0.92)
คำ 3309	ไป	ไปX (0.22)	ไป? (0.19)
คำ 3311	จีน	กรุงเทพX	กรุงเทพ? (0.27) **จีน?** (0.81) — เจอจีนแล้ว แต่มี segment เกินหน้าท่า
ประโยค 3302	สวัสดี ฉัน ชื่อ J ฉัน ชอบ แมว	สวัสดี ฉัน ชื่อ? ถูกX **ฉันX** ชอบ แมว?	สวัสดี ฉัน? ชื่อ? ถูกX **ฉัน?** ชอบ **แมว**
ประโยค 3303	ฉัน สบายดี คุณ สบายดี	ฉัน? สบายดีX คุณX สบายดี?	ฉัน? **สบายดี? คุณ?** สบายดี? (ถูก 4/4)
ประโยค 3304	วันนี้ ฉัน นำเสนอ งาน ภาษา มือ A I	วันนี้? ฉัน? ห้าX ทำงานX ภาษามือ? ยายX ถูก?	วันนี้? ฉัน? ห้า? ทำงาน? ภาษามือ? **A I** (ตัวอักษร, Accept)
ประโยค 3305	วันนี้ ฉัน อยาก เรียน ภาษา มือ	วันนี้? ฉัน? เกิด? เรียน ภาษามือ?	วันนี้? ฉัน? เรียน ภาษามือ? (อยาก = 1 คลิปใน bank)
ประโยค 3307	พรุ่งนี้ ฉัน ไป เที่ยว ประเทศ จีน	พรุ่งนี้? ฉัน? ไปX เที่ยว? กรุงเทพX แต่งงานX เกิดX	**พรุ่งนี้? ฉัน? ไปX เที่ยว? ประเทศ? จีน?** (ถูก 6/6)

สิ่งที่ยังพลาด (pattern จากวิดีโอจริง): **คำที่มี 1 คลิปใน bank** (นำเสนอ → ห้า, งาน → ทำงาน, อยาก หาย) · **J ตัวเดียว** กลางประโยค (ตัวอักษรเดี่ยวต้อง P ≥ 0.98 เพื่อกันตัวอักษรแทรกในประโยคคำ; J ได้ 0.96) · คำถูกส่วนใหญ่อยู่ระดับ "อาจหมายถึง" (P 0.6–0.9) เพราะ τ_accept 0.92 ล็อกที่ precision ≥ 0.90 — ประโยคที่เว็บพูดจึงสั้น (ใช้เฉพาะคำ Accept). ภาพทุกคลิป (เฟรม + กล่องคำ + P ของ v7.2 / v8 / v8.1): `lab2.ipynb` → 2-4.

5. Release gates (ก่อนแนะนำให้ใช้ v8.1)

#	Gate	ผล
1	Recognition ดีขึ้นบน held-out หลัก	✅ ทุกชุด test (CI ไม่คร่อม 0 บน TSL51 ทุกความเร็ว + ประโยคลื่น)
2	Accepted precision ≥ เป้า 0.90 (กำหนดก่อนทดลอง)	✅ ต่ำสุด 0.953 (TSL51 2×)
3	Calibration น่าเชื่อถือบนข้อมูลอิสระ	⚠️ ผ่านแบบมีเงื่อนไข — ECE 0.03–0.07 (v7.2 0.11–0.18) แต่สูงกว่า v8 (0.03–0.05) บน 4/5 ชุด
4	False merge ไม่กินผล segmentation	⚠️ Seg F1 เท่าเดิม (±0.002) หรือดีขึ้น (TSL51 2× 0.805 → 0.818); count error ดีขึ้น 3/5 ชุด test, แย่ลง TSL51 1× (0.286 → 0.349) และคำเดี่ยว (0.083 → 0.088)
5	Guard คำซ้ำไม่กดคำซ้ำจริง	✅ คำถูกที่ถูก Reject 5–8% → 0–2%; "ฉัน" ซ้ำใน 3302 ไม่ถูก Reject
6	OOV / ตัวอักษรไม่กลายเป็นคำมั่นใจ	✅ false-accept ≤ 0.056; ตัวอักษรแทรกผิด 0 บน tune; วิดีโอจริง accepted precision 1.0
7	API เดิมใช้ได้	✅ `docker compose build sign-api` + `/v1/translate/video` ด้วยคลิป iPhone: ผลตรงกับ Python ทุกคำ, field เดิมครบ
8	Runtime / memory	✅ 621 ms ต่อคลิป 7.3 s (v8 546 ms, +14%) = 85 ms ต่อวินาทีวิดีโอ · RSS 726 MB (เท่า v8) · MediaPipe 28 ms/เฟรม (เท่าเดิม)

Go — แนะนำ v8.1 เป็น forward หลัก: ทายคำถูกขึ้นชัดและมีนัยสำคัญทุกชุด, ไม่มี WER ชุดไหนแย่ลง, ความแม่นของคำที่ Accept ยังเกินเป้า. ข้อแลกที่ต้องรู้: §6.

---

6. แย่ลง / ยังไม่ได้ (ตรงๆ)

- **Calibration (ECE) แย่กว่า v8 เล็กน้อย** บน TSL51 1×/1.5×, คำเดี่ยว, ประโยคลื่น (0.04 → 0.06 โดยประมาณ) — คำที่ยังผิดตอนนี้เป็นคำที่ "เกือบถูก" (P เฉลี่ยของคำผิด 0.29 → 0.42) จึงแยกยากขึ้น. ลอง feature ใหม่ 3 ชุด (hand cue, decoder-agree, split/rerank flag) บน tune CV แล้ว **ไม่ดีขึ้นเกิน noise** → ไม่ปรับต่อโดยดู test (จะกลายเป็นจูนบน test)
- **คำที่ Accept ได้ถูกบน TSL51 1.5× / 2× ลดลง** 135 → 125 / 130 → 122 (τ_accept 0.90 → 0.92 จากเกณฑ์ precision ≥ 0.90 ทุกชุด tune) — คำถูกเหล่านั้นยังแสดงเป็น "อาจหมายถึง" ไม่หายไป; รวมทุกชุด test: 530 → 523
- **Count error**: TSL51 1× 0.286 → 0.349 · คำเดี่ยว 0.083 → 0.088 · data_test 0.6 → 1.0 (ประโยค "ฉันปลอบเพื่อนร้องไห้" / "ไปทานข้าวด้วยกันมั้ย" ได้ segment น้อยลง 1–2 · test1 ถูก split เพิ่ม 1) · iPhone คำ 0.111 → 0.222 (จีน มี segment เกินหน้าท่า)
- Recall@5 คำเดี่ยว 0.925 → 0.917, data_test 0.85 → 0.76 (top-1 ดีขึ้น แต่ top-5 ของบางคลิปเปลี่ยน)
- **J ตัวเดียว** ยังไม่ขึ้น · ตัวอักษรไทยไม่เปิดอัตโนมัติ (แทรกผิดเยอะ)
- data_test ยังสูง (WER 0.684): 3/5 คลิปทำท่าลื่นมาก — split test ช่วยได้เฉพาะเมื่อ tagger เห็นอย่างน้อย 2 ท่าแล้ว
- Latency +75 ms ต่อคลิป (hand cue + สะกดนิ้วทุก utterance)

---

7. ข้อมูลที่ควรเก็บเพิ่ม (เรียงตามผลกระทบ)

คอขวดใหญ่ที่สุดที่เหลือ = **คนทำท่าต่อคำ**. คำสนทนา (หลังรวมท่าแบบอื่นแล้ว) ที่มี **1 คน = 68 คำ**, **2 คน = 79 คำ**. เรียงตามความถี่ภาษาไทย (TNC) — คำที่พบบ่อยมากแต่มีคนทำท่าคนเดียว:

1. **1 คน, ใช้บ่อยที่สุด:** เป็น มี และ ไม่ ได้ ให้ แต่ ต้อง ด้วย ใช้ อีก เธอ ถ้า ถูก เอา **งาน** กลับ คิด เคย **อยาก** กำลัง เงิน ควร ...
2. **2 คน, ใช้บ่อย:** มา คน อยู่ เขา มาก เรา ยัง เห็น ก่อน รู้ ชีวิต ปัญหา ใคร ใช่ ...
3. **คำที่ผิดบน iPhone เพราะข้อมูล:** อยาก, นำเสนอ, งาน (1 คลิป), ไป (ท่าของผู้ทดสอบต่างจาก reference)

4. **ชุดวัดผลจริง**: ประโยคจริง 30–50 ประโยค หลายคน (ใช้วัดผลอย่างเดียว) — ชุด iPhone ปัจจุบันเป็นคนเดียว 14 คลิป ต่างกัน 1 คลิป = สรุปไม่ได้
5. วิดีโอทำท่าลื่น/เร็วจริงหลายคน (มี boundary) — สำหรับเทรน tagger รอยต่อที่ไม่มีการพักมือ

รายการเต็ม: `python main.py decision report` → `artifacts/reports/decision_v8.1.json` · ลิสต์คำ 1–2 คนคำนวณจาก `models/bank.npz` + `vocab_conversation.json` (variants).

---

8. Reproduce · ไฟล์ · Rollback

```
python main.py decision cache                # front pass ของทุกชุด (CPU ~12 นาที, cache/decision ~0.6 GB — ลบได้)
python main.py decision hands                # hand-shape descriptor ของทุกคลิปใน bank + metric (คน train) ~1 นาที
python main.py decision tune --write         # เลือกทุกค่าบน tune (CPU ~70 นาที) → models/
python main.py decision report               # v7.2 / v8 / v8.1 บน test + วิดีโอจริง →
artifacts/reports/decision_v8.1.json
python main.py decision figures              # result_reporting/figures_v8.1/
```

ไฟล์	เปลี่ยนอะไร
`models/hand_bank.npz` (ใหม่, 2.7 MB) · `artifacts/eval/hand_bank_eval.npz`	descriptor ของ bank (projected 64 มิติ) + metric
`models/spotting.json`	`hand_w` 1.2, `split` (thr 0.7, ≥ 2 ท่า), `grammar` guard, `post.repeat_keep_p` 0.8, `spell` ใหม่, `"alphabet": "en"`
`models/segment_calibration.json`	temperature 0.086, P(correct), re-ranker, τ 0.92 / 0.15
`models/vocab_conversation.json` · `vocab/daily_conversation.json`	+ จีน ประเทศ (328 คำ), `variants` 61 แบบ
`models/class_prior.npz`, `models/config.json`	ความน่าเชื่อถือของคำ (รวม variants) · version v8.1
`artifacts/baselines/v8/`	การตั้งค่า v8 ทั้งชุด (baseline + rollback)

Rollback → v8: `copy artifacts\baselines\v8\* models\` (spotting, segment_calibration, class_prior, vocab_conversation) — โค้ดใหม่อ่านไฟล์ v8 ได้ (ไม่มี `hand_w` = ไม่ใช้ hand cue, ไม่มี `split` / `grammar` / `variants` = พฤติกรรม v8). **Rollback → v7.2:** `git checkout f08a56d -- models/spotting.json models/segment_calibration.json models/vocab_conversation.json` + ลบ `models/class_prior.npz`. Docker: `docker compose build sign-api` (โค้ดอยู่ใน image, `models/` mount) — ไม่ต้องเพิ่ม dependency (hand cue ใช้ NumPy อย่างเดียวตอน inference).

---

9. Cost & cleanup

รายการ	ค่าใช้จ่าย
Vertex AI / GPU	**$0** — ไม่ได้ใช้ (งานรอบนี้ไม่ต้องเทรน encoder; ทุกขั้น CPU บนเครื่อง: hand descriptor 1 นาที, tune ~70 นาที, report ~25 นาที)
Cloud Storage	$0 — ไม่ได้อัปโหลด; bucket `temp-gpu-bucket-job` ว่าง (0 object)
AWS S3	ไม่ได้ push (อ่าน mirror ในเครื่องเท่านั้น)

ตรวจหลังจบ: Vertex custom jobs = 0 ทั้ง asia-southeast1 / us-central1 / europe-west4 · bucket 0 object (คง bucket ไว้) · Compute Engine VM / disk = 0 · container ทดสอบ Docker ถูกหยุด/ลบ · ไม่มี background process ของงานนี้ค้าง.