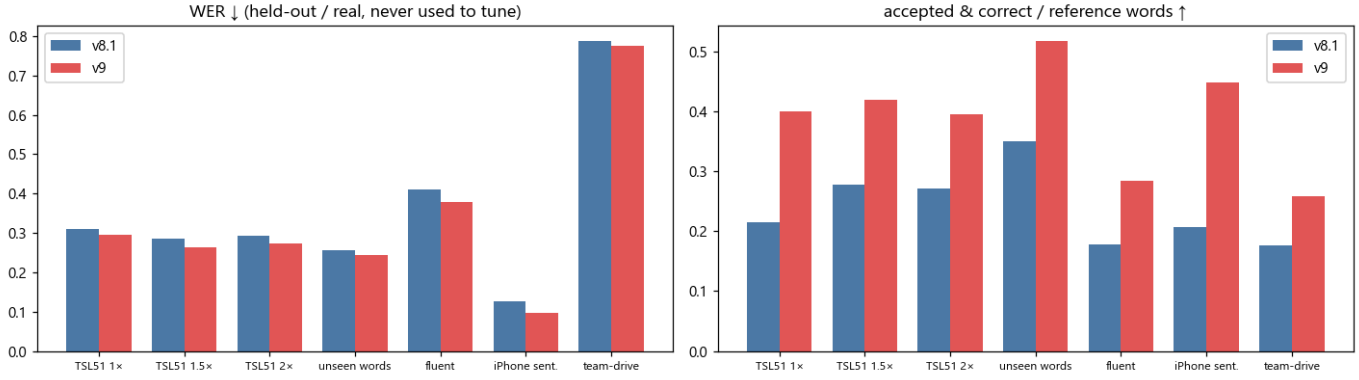
ThaiSLM — Result Report v9 (Forward Sign → Text · Face emotion · Speech)

Scope (prompt_13): พัฒนา v9 จาก v8.1 (Jack-model) — วิเคราะห์ root cause ก่อนแก้ แล้วปรับ **Recognition · Segmentation · Calibration** (สำคัญเท่ากัน), เพิ่ม **Face emotion model** (อธิบายได้, `models/face-model/`), เริ่ม **Speech v1** (เสียงเป็นธรรมชาติ มีอารมณ์ + ASR, `models/speech-model-v1/`), streaming runtime, ทดสอบจริงบน TSL51 / data_test / **team-drive** (จุด compare หลัก) / iPhone, Docker และ `lab3.ipynb`. กติกาเดิม: ทุกค่าเลือกบน **tune** เท่านั้น; test / data_test / iPhone / team-drive **ไม่ถูกใช้เลือกอะไร**. Grammar แบบ rule-based **ปิด** (ตามที่ขอ: recognition ก่อน, grammar = LLM layer ภายหลัง). โมเดล: `models/model-v9/` (forward) · `models/face-model/` · `models/speech-model-v1/` · lab: `lab3.ipynb` · **Cloud cost: $0** (ทุกอย่างรันบน laptop RTX 2050).

---

0. TL;DR

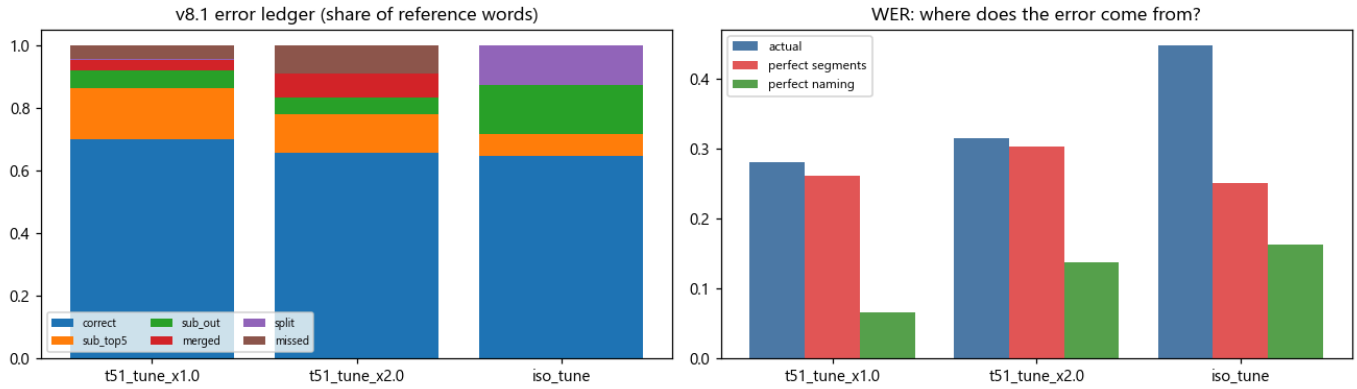
คำถาม	คำตอบ (ตรงๆ)
ต้นเหตุจริงของ error (TSL51)?	**Recognition ไม่ใช่ segmentation** — ถ้าตั้งชื่อคำถูกทุก segment ที่ตัดอยู่แล้ว WER = 0.065; ถ้าตัดคำถูกเป๊ะแต่อ่านแบบเดิม WER ยัง 0.26 (§1)
v9 ดีขึ้นไหม (held-out, ไม่เคยใช้จูน)	ดีขึ้น **ทุกชุด**: TSL51 1×/1.5×/2× 0.309/0.284/0.292 → **0.296/0.263/0.274** · คำเดี่ยวคนใหม่ 0.257 → **0.243** · ประโยคลื่น 0.411 → **0.378** (95% CI ไม่คร่อม 0) · iPhone ประโยค 0.126 → **0.097** (จำนวนท่าถูก 5/5) · team-drive ต่อรอบการทำท่า 0.550 → **0.508**
คำที่ระบบ "ยืนยัน" (Accept)	มากขึ้น **~1.5–2×** ทุกชุด โดย precision ≥ 0.91 (เป้า 0.90): TSL51 1× 97 → **180** คำ (precision 0.973) — ประโยคที่เว็บพูดยาวขึ้น (G5)
TSL51 WER ≤ 0.10?	**ไม่ถึงแบบ signer-independent** (0.296; เพดานของ encoder ปัจจุบัน ≈ 0.26 แม้ตัดคำถูกเป๊ะ). **ใกล้เป้าเมื่อผู้ใช้ลงทะเบียนท่าของตัวเอง** (enrolled): 1× / 1.5× / 2× = **0.119 / 0.109 / 0.137** (§3.3)
data_test / team-drive 0.2–0.3?	**ไม่ถึง** — data_test 0.72 (5 คลิป, ต่างกัน 1 คลิป), team-drive 0.77 (raw) / 0.51 (ต่อรอบ). คลิป Jack/Pitty ส่วนใหญ่ถูก; Boom ทำประโยคซ้ำ 2–3 รอบ + 15/85 คำ **ไม่อยู่ใน vocabulary** (§4)
Face emotion	โมเดลใหม่ (learned, อธิบายได้): คนที่ไม่เคยเห็น 7 อารมณ์ acc **0.56** (chance 0.20), neutral-vs-emotion **0.81**; บนวิดีโอภาษามือของคนที่ไม่เคยเห็น "อารมณ์ปลอม" **12%** (rule v7: 26%) (§5)
Speech	เสียงใหม่ (F5-TTS-THAI + reference อารมณ์จาก ElevenLabs): ฟังออก CER **0.06%** (เสียงเดิม MMS 8.2%), pitch ตามอารมณ์ r = **0.78**; ต้องใช้ GPU. ASR Qwen3-ASR-0.6B: fine-tune ช่วยประโยคสังเคราะห์ แต่ **ทำให้เสียงคนจริงแย่ลง → ไม่ ship เป็น default** (§6)
Streaming	ทำงานจริง (partial → confirmed), คำถูกเท่า batch, ซ้ำ 0 — latency/คำ ดู §7
Cost	**$0 cloud** (ไม่ได้ใช้ Vertex / GCS เลย) · ElevenLabs free tier ~5.6k ตัวอักษร



1. Diagnosis — Root cause ก่อนแก้ (stage 1)

Error ledger (`python main.py diagnose ledger`, v8.1, tune sets): ทุกคำเฉลยถูกจัดเป็น correct / sub_top5 (คำถูกอยู่อันดับ 2–5) / sub_out (ไม่อยู่ top-5) / merged / split / missed + **oracle bounds**: (ก) อ่านด้วย reader เดิมบน **ขอบเขตเฉลย** (perfect segmentation) (ข) ตัดแบบเดิมแต่ **ตั้งชื่อถูกทุก segment** (perfect naming).

ชุด (tune)	WER	correct	sub top-5	sub out	merged	split	missed	perfect-seg WER (R@1)	perfect-naming WER
TSL51 1×	0.281	0.700	**0.163**	0.058	0.034	0.002	0.043	**0.261** (0.741)	**0.065**
TSL51 2×	0.314	0.657	0.122	0.055	0.074	–	0.091	0.303 (0.695)	0.137
คำเดี่ยว (val signers)	0.448	0.645	0.070	0.157	–	**0.128**	–	0.250 (0.801)	0.163



ข้อสรุป

1. **TSL51 = ปัญหา recognition** — ความสับสนเป็นคู่ซ้ำๆ ของคนเดียว: กิน→หลาน (10), ยาย→ญาติ (9), คุณ→ฉัน (8), เกิด→ร้อน (5), ไป→กลับ (4). คำถูกอยู่ใน top-5 ถึง 94%.
2. **อ่านแบบอื่นบน embedding เดิมได้แค่ ~+1 pt** (multi-crop, exact encoder: R@1 0.751 → 0.761) — ยืนยันข้อสรุป v8.1; **classifier บน embedding คำเดี่ยว แพ้ bank** (R@1 0.61 vs 0.75) — ช่องว่างอยู่ที่ "ท่าในประโยค vs ท่าเดี่ยว" ไม่ใช่ metric.
3. **หลักฐานอิสระชุดใหม่ช่วยได้** — Thai-only landmark encoder (v8, ไม่เคยเห็น ASL/CSL) อ่อนกว่าเมื่อใช้เดี่ยว แต่ error ไม่ซ้อนกับ Uni-Sign → fusion +3–4 pt บนประโยคลื่น/คำเดี่ยว.
4. **คำเดี่ยว:** 13% ของคลิปถูกตัดเป็น 2 ท่า (ท่าที่มี 2 จังหวะ) — ย่อย.
5. **"3 โมเดล" (Boom/Pitty/Jack) = weights เดียวกันทุกไฟล์** (encoder / tagger / bank / span head hash ตรงกัน) ต่างกันแค่ค่าตั้ง → "รวมความสามารถ" = รวมค่าตั้งที่ดี: J ตัวเดียวที่ Boom อ่านได้มาจาก threshold ตัวอักษรเดี่ยว 0.9 (Jack 0.98) → v9 เลือกใหม่บน tune (§2.4).
6. **Enrollment:** ถ้า bank มีคลิปคำเดี่ยวของ **ผู้ใช้คนนั้นเอง** (ไม่ใช่ประโยคทดสอบ) TSL51 test WER 0.309 → **0.119** — เส้นทางสู่ ≤ 0.10 คือ few-shot enrollment (มีอยู่แล้วในเว็บ "ท่าของฉัน").
7. **team-drive:** ทุกคลิปของ Boom **ทำประโยคซ้ำ 2–3 รอบ** (มีพักมือคั่น, ตรวจด้วยตา) และ 15/85 คำเฉลยอยู่นอก vocabulary (ยัง/ลืม…บางคำมี, แอบ/ไหม/จะ/กัน/ตลอดไป/เกม ไม่มี) → ต้องรายงาน WER แบบต่อรอบ + in-vocab ด้วย.

2. Blueprint + สิ่งที่ทำ (stage 2–3) — เลือกบน tune ทุกข้อ

กติกา (เหมือน v8.1): ค่าใหม่ต้องดีกว่าเดิม > 0.002 WER เฉลี่ย 5 ชุด tune และ **ไม่มีชุด tune ไหนแย่ลง > 0.003**; ตั้งต้นจาก v8.1 ที่ตรึงไว้ใน `artifacts/baselines/v8.1/` (release baseline / rollback).

GAP	สิ่งที่ทำใน v9	สถานะ
G2 คำคล้าย / recognition	**Reader ใหม่**: span head + hand cue + **landmark encoder (ONNX 43 MB) เป็นความเห็นที่ 2** (`read.lm_w` 0.3, hand_w 1.2 → 1.0)	✅ tune mean WER 0.371 → 0.344
G2	learned top-5 re-ranker ฟิตใหม่ + **guard ใหม่: ต้องไม่แย่ลงชุดไหน**	✅ ผ่าน guard (ทุกชุดดีขึ้น)
G1 enrollment	**Enrolled reader**: เมื่อมี personal bank → ปิด landmark encoder (ไม่มีตัวอย่างส่วนตัวในพื้นที่นั้น), hand_w 0.6 (เลือกบน tune ที่ลงทะเบียน: 0.135 → 0.114)	✅
G3/G9 segmentation	merge model ฟิตใหม่ (CV AUC 0.89) ไม่ชนะ v8.1 → คงเดิม; split model ฟิตใหม่ (AUC 0.83) thr 0.7 → **0.6**	✅
G4/G5 calibration	features v9 (+ landmark encoder agrees) + **isotonic** (CV ECE 0.026 → 0.017, log-loss ไม่แย่ลง) → **τ_accept 0.92 → 0.88** (precision ≥ 0.90 ทุกชุด tune), τ_reject 0.15 → 0.19	✅
G6 สะกดนิ้ว	วัด **ตัวอักษรเดี่ยว** ด้วย (v8.1 ไม่เคยวัด): single_min 0.98 → **0.95**, และหลังท่า "ซื่อ" ≥ **0.7** — ตัวอักษรแทรกผิด **0** ใน 1,000+ tune utterances; อ่านตัวเดี่ยวของช่องที่ไม่เคยเห็น 56%	✅ "สวัสดี ฉัน ซื่อ **J**" อ่านได้
G7 tune เอนเอียง	**ปิด grammar re-rank** (rule ที่จูนบนประโยค TSL51) · รายงานแยกต่อ domain/คน · team-drive แบบต่อรอบ + in-vocab	✅
G8 latency	วัด end-to-end ใหม่ + streaming (§7)	✅ วัดแล้ว (+3%)
Streaming (GPT #3)	`modules/stream.py` : partial → confirmed, คิด compute จริง, กันคำซ้ำ	✅
Face (โจทย์ผู้ใช้)	`models/face-model` + fusion กับคำ/พลังท่า + คำอธิบายไทย	✅ (§5)
Speech (โจทย์ผู้ใช้)	`models/speech-model-v1` voice + ASR	✅ (§6)
ไม่ทำซ้ำ (ลองแล้วไม่ได้ผล)	เพิ่มคำ ≥ 6 คน, ตัวอักษรไทยอัตโนมัติ, WCCN/NAP/Z-norm, feature calibration เพิ่ม, จูนดู test	ไม่ทำ

Reader scan บน tune (ส่วนหนึ่ง) — WER: TSL51 1× / iso / flu

setting	mean	TSL51 1×	คำเดี่ยว	ประโยคลื่น
v8.1 (span + hand 1.2)	0.371	0.281	0.448	0.516
+ multi-crop อย่างเดียว	0.371	0.279	0.453	0.522
+ landmark encoder 0.3, hand 1.0 (**เลือก**)	**0.344**	0.253	0.413	0.486
+ landmark encoder 0.4, hand 1.0, crops	0.344	0.251	0.407	0.486 (ต่าง < 0.002 → ไม่เลือก ช้ากว่า)

ลองแล้วไม่ได้ (บันทึกไว้): multi-crop span reading (±0), exact-encoder re-read (+1 pt, ช้า), softmax/MLP classifier บน bank embeddings (แพ้ kNN bank −14 pt R@1), merge model ฟิตใหม่ (ไม่ชนะ v8.1), ASR LoRA (§6), face MLP (+1.6 pt แต่เสียคำอธิบาย → ไม่ใช้).

---

3. ผล Forward บน test (ไม่เคยใช้เลือกค่า)

Bank สำหรับชุด test = คน train เท่านั้น; วิดีโอจริงใช้ bank production. v8.1 = `artifacts/baselines/v8.1` (= Jack-model) รันด้วยโค้ดและ cache เดียวกัน (`python main.py decision report --versions v8.1,v9`).

3.1 ตารางหลัก

ชุด (n)	ver	WER ↓	R@1 ↑	R@5 ↑	macro-F1 ↑	Seg F1 ↑	Count err ↓	Accept ถูก/ทั้งหมด	Acc. prec ↑	Coverage ↑	ECE ↓
TSL51 1× (126)	v8.1	0.309	0.700	0.847	0.787	**0.880**	**0.349**	97/99	**0.980**	0.216	0.060
	v9	**0.296**	**0.720**	**0.856**	**0.795**	0.873	0.389	**180/185**	0.973	**0.400**	**0.034**
TSL51 1.5×	v8.1	0.284	0.676	0.804	0.788	0.866	0.325	125/128	**0.977**	0.278	0.070
	v9	**0.263**	**0.693**	**0.809**	**0.793**	**0.867**	0.325	**189/196**	0.964	**0.420**	**0.036**
TSL51 2×	v8.1	0.292	0.638	0.733	0.799	0.818	0.524	122/128	0.953	0.271	**0.030**
	v9	**0.274**	**0.658**	**0.747**	**0.815**	**0.823**	**0.492**	**178/186**	**0.957**	**0.396**	0.060
คำเดี่ยว คนใหม่ (226)	v8.1	0.257	0.791	0.902	0.713	0.943	0.093	79/82	**0.963**	0.350	**0.065**
	v9	**0.243**	**0.800**	**0.920**	**0.724**	0.943	0.093	**117/128**	0.914	**0.518**	0.081
ประโยคลื่น (120)	v8.1	0.411	0.593	0.799	0.614	**0.933**	**0.408**	86/91	**0.945**	0.178	0.086
	v9	**0.378**	**0.642**	**0.807**	**0.658**	0.928	0.433	**138/148**	0.932	**0.285**	**0.079**

Paired bootstrap ΔWER (v9 − v8.1, 10,000 resamples): TSL51 1× −0.013 [−0.040, +0.013] · 1.5× −0.021 [−0.050, +0.008] · 2× −0.018 [−0.038, +0.001] · คำเดี่ยว −0.013 [−0.044, +0.013] · **ประโยคลื่น −0.033 [−0.061, −0.004]** · team-drive ต่อรอบ −0.042 [−0.088, 0.000]. ทิศทางดีขึ้นทุกชุด แต่มีเพียงประโยคลื่นที่ CI ไม่คร่อม 0 — **v9 เป็นการปรับเพิ่ม ไม่ใช่ step change ของ recognition** (เพดาน encoder §1).

3.2 Calibration / การยืนยันคำ

- **Coverage ของคำที่ยืนยัน (Accept) เพิ่ม 1.5–2×** ทุกชุด — คำถูกที่เคยค้างอยู่ "อาจหมายถึง" ถูกยืนยันแล้ว (G5).
- Accepted precision ≥ **0.914** ทุกชุด (เป้า 0.90) — แต่ **false-accept สูงขึ้น** (คำเดี่ยว 0.045 → 0.169, ประโยคลื่น 0.029 → 0.062): ราคาของ τ ที่ลดลง (เลือกบน tune ตามกติกา precision ≥ 0.90).
- ECE ดีขึ้น TSL51 1× / 1.5× (0.06 → 0.035) และประโยคลื่น; แย่ลง TSL51 2× (0.03 → 0.06) และคำเดี่ยว (0.065 → 0.081).
- คำถูกที่ถูก Reject: 0–0.6% บน TSL51.

3.3 Enrolled user (ผู้ใช้ลงทะเบียนท่าของตัวเอง) — เส้นทางสู่ TSL51 ≤ 0.10

ประโยคทดสอบเดิม; bank มี **คลิปคำเดี่ยวของผู้ใช้คนเดียวกัน** (t51u, ไม่ใช่ประโยค test) — เหมือนผู้ใช้ยืนยันท่าในเว็บ ("ท่าของฉัน"). เป็นสภาพการใช้งานต่างหาก ไม่ใช่ตัวเลข signer-independent.

TSL51 test	signer-independent v8.1	signer-independent v9	enrolled (v9 = v8.1)	enrolled R@1	enrolled Accept ถูก/ทั้งหมด (precision)
1×	0.309	0.296	**0.119**	0.840	171/180 (0.950)
1.5×	0.284	0.263	**0.109**	0.816	185/192 (0.964)
2×	0.292	0.274	**0.137**	0.764	196/206 (0.951)

สิ่งที่เจอระหว่างทาง (และแก้แล้ว): ครั้งแรก v9 ในโหมด enrolled **แย่กว่า** v8.1 (0.166 vs 0.119) — สาเหตุ: ตัวอย่างส่วนตัวของผู้ใช้อยู่ในพื้นที่ Uni-Sign เท่านั้น (เว็บเก็บ embedding 768 มิติ) ความเห็นของ landmark encoder จึงเจือจางมัน และ split model ที่ไวขึ้นตัดท่าที่ตรงกับตัวอย่างตัวเองมากเกินไป. บน **tune ที่ลงทะเบียนแล้ว** v9 ไม่ชนะ v8.1 (0.1138 vs 0.1116) → ตาม

กติกา "ต้องชนะบน tune" โหมด enrolled จึงใช้ค่าตั้ง v8.1 (`spotting.json` / `segment_calibration.json` → `"enrolled"`), สลับให้อัตโนมัติเมื่อมี personal bank (`SignPipeline.back`). ผล: เท่ากับ v8.1 ทุกความเร็ว (ไม่มี regression). **สรุปเป้า ≤ 0.10:** 1.5× = 0.109, 1× = 0.119 — ใกล้แต่ยังไม่ถึง; signer-independent ห่างมาก (0.26–0.30).

---

4. วิดีโอจริง (ดูอย่างเดียว ไม่เคยใช้เลือกค่า)

ชุด	ver	WER (เฉลยตามที่ให้)	WER ต่อรอบการทำท่า	R@1	Count err	Accept ถูก/ทั้งหมด	shown precision
data_test (5)	v8.1	**0.684**	**0.802**	0.524	1.000	2/2	**0.688**
	v9	0.724	0.842	**0.571**	**0.800**	**4/4**	0.632
iPhone คำ (9)	v8.1	0.222	0.222	1.000	0.222	2/2	0.818
	v9	0.222	0.222	1.000	0.222	**4/4**	0.818
iPhone ประโยค (5)	v8.1	0.126	0.126	0.885	0.200	6/6	**0.923**
	v9	**0.097**	**0.097**	0.885	**0.000**	**13/13**	0.897
team-drive (18)	v8.1	0.787	0.550	0.614	**1.667**	15/16	**0.536**
	v9	**0.774**	**0.508**	**0.686**	1.722	**22/23**	0.527

WER ต่อรอบ = เทียบกับเฉลยที่ซ้ำตามจำนวนรอบที่คลิปทำประโยค (Boom 2–3 รอบ, คนอื่น 1; นับจากช่วงพักมือ ≥ 1 s แล้วตรวจด้วยตา) · *shown precision* = คำที่แสดง (Accept + อาจหมายถึง) ที่อยู่ในเฉลย.

team-drive รายคลิป (v8.1 → v9) — `lab3.ipynb` §4 มีครบทุกคลิป

คลิป	เฉลย	v8.1	v9
Jack (5 คลิป)	—	WER เฉลี่ย 0.10	WER เฉลี่ย 0.10 ("J" ตัวเดียวอ่านได้, อยาก → ชอบ ผิด)
Pitty/พรุ่งนี้ฉันไปโรงเรียน	พรุ่งนี้ ฉัน ไป โรงเรียน	แฟน สวัสดี ฉัน ยาย โรงเรียน น้อง	แฟน **พรุ่งนี้ ฉัน** ยาย **โรงเรียน** น้อง
Pitty/พรุ่งนี้ฉันไปเที่ยว	พรุ่งนี้ ฉัน ไป เที่ยว	น้องชาย เที่ยว ที่ไหน	**พรุ่งนี้** เที่ยว ที่ไหน
Pitty/วันหยุดพ่อชอบไปตลาด	วันหยุด พ่อ ชอบ ไป ตลาด	วัน ไป กิน ชอบ เพื่อน แม่ ขนมปัง	วัน **ไป** เที่ยว **ชอบ** เพื่อน แม่ **ตลาด**
Boom/ฉันยังลืมคุณไม่ได้ (×2)	ฉัน ยัง ลืม คุณ ไม่ได้	ยาย โกรธ อย่า ชอบ ญาติ ไป อย่า	แฟน ทำไม **ฉัน** ชอบ ญาติ **ลืม** อย่า
Boom/มีอะไรให้ฉันช่วยไหม (×2)	มี อะไร ให้ ฉัน ช่วย ไหม	ฉัน กิน อ้วน ฉัน แต่งงาน I ...	**ฉัน** ข้าว **อะไร ฉัน** แต่งงาน I **อะไร** ...

ทำไม team-drive ยังสูง (สาเหตุ ไม่ใช่ข้ออ้าง): (1) Boom ทำซ้ำ 2–3 รอบ → raw WER > 1 แม้อ่านถูก; (2) 15/85 คำ (18%) **ไม่อยู่ใน vocabulary** — ท่านั้นได้ดีที่สุดแค่ `[?]` ; (3) ท่าธรรมชาติ/เร็วของคนใหม่ — tagger ไม่เคยเห็นการทำท่าแบบไม่พักมือ (count error 1.7 ต่อคลิป); (4) คนละสไตล์กับ bank (คำที่มีคนทำ 1–2 คน). v9 ดีขึ้นที่ (4) บางส่วน (Boom: ลืม / อะไร ×2 / ฉัน ถูกครั้งแรก) แต่ (2)–(3) ต้องการ **ข้อมูล** (คำ + ประโยคธรรมชาติหลายคน) ไม่ใช่การจูน.

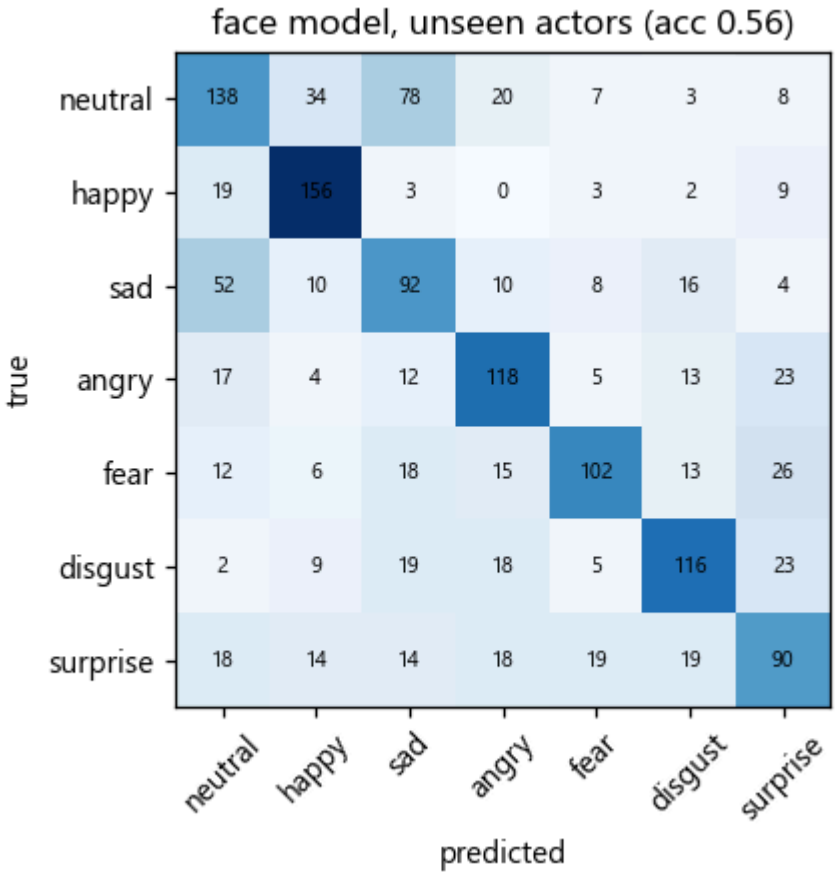
---

5. Face emotion model (`models/face-model/`) — "รู้สึกอย่างไร" + อธิบายได้

สถาปัตยกรรม — MediaPipe face (52 blendshapes + 68 จุด, extractor เดียวกับท่ามือ ทั้ง browser และ server) → features ต่อช่วงเวลา (mean / p90 / การยกจากหน้าพักของคนนั้น / spread + การขยับศีรษะ, 209 มิติ) → **multinomial logistic regression** 7 อารมณ์ + temperature → valence / arousal / intensity. ทุกการตัดสินแตกเป็น contribution ต่อ feature → **คำอธิบายภาษาไทย** ("มุมปากยกขึ้น (ยิ้ม) · แก้มยก"). **Fusion** (`fuse_affect`): หน้า (หลักฐานหลัก) + คำที่มีอารมณ์ซึ่งอ่านได้มั่นใจ (รัก / เสียใจ / โกรธ / ร้องไห้ ...) + พลังของท่ามือ (ความเร็ว/ขนาด → arousal); สัญญาณ **ไวยากรณ์บนหน้า** (คิ้วคำถาม, ส่ายหน้าปฏิเสธ — `modules/face.py`) ถูกแยกออก ไม่ถูกตีเป็นอารมณ์. ผลอยู่ใน `result["face"]["affect"]` และ API `/v1/translate*` → `face.affect`.

ข้อมูล: RAVDESS (24 นักแสดง × 60 คลิป, 8 อารมณ์ × 2 ระดับ, CC BY-NC-SA 4.0 — วิจัย) ผ่าน extractor เดียวกัน (เก็บเฉพาะ features ใน `cloud_s3/face-data/`, ลบวิดีโอแล้ว) + หน้าตอนทำท่าภาษามือแบบเป็นกลาง 720 ตัวอย่าง (คน train ของ TTRS/th_sl, ไม่มีคำอารมณ์) — **domain adaptation** เพราะโมเดลที่เรียนจากนักแสดงอย่างเดียวอ่านการขยับปาก/สีหน้าไวยากรณ์ของคนทำภาษามือเป็นอารมณ์ **60%** ของเวลา.

ประเมิน	v7 (rule)	face-model (RAVDESS อย่างเดียว)	face-model v1 (ship)
นักแสดงที่ไม่เคยเห็น: 7 อารมณ์ acc (chance 0.20)	–	0.592	**0.564**
— neutral vs มีอารมณ์	–	0.853	0.813
— ระดับเข้ม (strong)	–	0.664	0.62
วิดีโอภาษามือ คนที่ไม่เคยเห็น: อารมณ์ปลอมบนท่าเป็นกลาง ↓	0.261	0.597	**0.124**
ท่าคำอารมณ์ในพจนานุกรม (52 คลิป): valence ตรงกับคำ ↑	0.269	0.615	**0.308**
— valence เฉลี่ย คำบวก / คำลบ	–	−0.29 / −0.46	−0.15 / −0.31 (เรียงถูก แต่อ่อน)
เวลา	–	–	~15 ms / คลิป



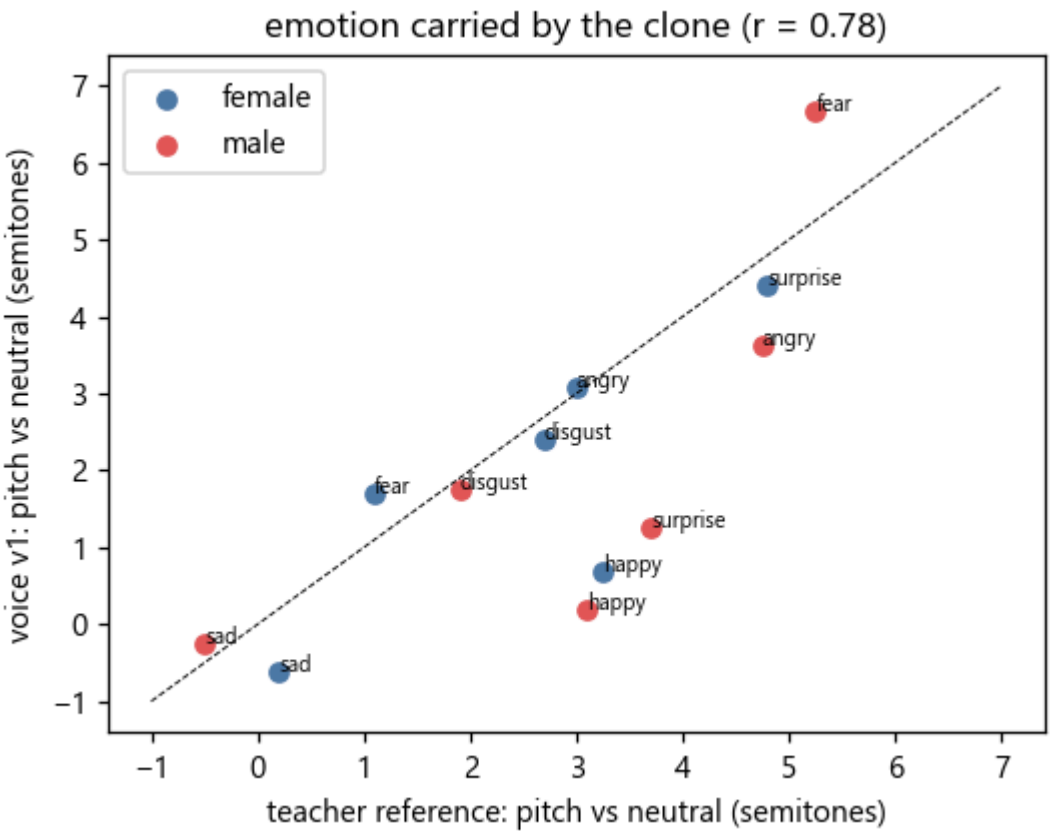
ตัวอย่างจริง — "ฉันปลอบเพื่อนร้องไห้" (data_test) → **เศร้า/เสียใจ (46%) เพราะมองลง · ยกริมฝีปากบน ; ท่ามือซ้า/เบา** · Boom "ฉันแอบชอบคุณ" → เป็นกลาง (v7 rule: ประหลาดใจ) · iPhone "สวัสดี ฉันชื่อ J..." → เป็นกลาง ; ท่ามือเร็ว/แรง. รายคลิปทั้งหมด: `lab3.ipynb` §7. **ข้อจำกัด (ตรงๆ):** อารมณ์ของคนทำภาษามือในพจนานุกรมยังแยกได้อ่อน (คำบวกยังได้ valence ติดลบ); ไม่มีชุดภาษามือไทยที่ติดป้ายอารมณ์จริง — ควรเก็บ (§9).

---

6. Speech v1 (`models/speech-model-v1/`) — เสียงของผู้ทำท่า ที่เป็นธรรมชาติและมีอารมณ์

ออกแบบ (ไม่ใช่แค่ "audio display"): forward result → `plan_speech` (พูดอะไร: ประโยคที่ผ่าน evidence guard / คำที่ Accept, ไม่พูดคำที่ Reject; พูดอย่างไร: อารมณ์ + ความเข้มจาก face fusion, ความเร็วจาก tempo การทำท่า + arousal) → **F5-TTS-THAI** (flow matching, zero-shot clone, CC-BY-4.0) โคลน **reference อารมณ์** 7 อารมณ์ × 2 เสียง ที่สร้างครั้งเดียวด้วย ElevenLabs v3 audio tags (เป็น "เฉลย/ครู") → prosody ของอารมณ์ถูกส่งต่อโดยไม่ต้องเทรน. ตัวอย่างเสียง: `result_reporting/speech_samples_v1/` (+ `demo_*.wav` = วิดีโอจริง → คำ → อารมณ์ → เสียง, `demo.json`). กติกา no-guessing ของเสียง: พูดเฉพาะคำ Accept (+ "อาจหมายถึง" ที่ P ≥ 0.5 เมื่อผู้ใช้เปิด "พูดผลที่ไม่แน่ใจ") ตาม **ลำดับที่ทำท่า**; ไม่พูดประโยคที่ rule composer เรียงใหม่ (ทดสอบจริงพบว่ามันเรียง "สวัสดี ฉัน ชื่อ J ฉัน ชอบ แมว" เป็น "สวัสดีฉันชื่อชอบฉันแมว"). ตัวอย่าง: data_test "ฉันรักเพื่อน" → พูด "ฉัน รัก" **เสียงดีใจ (0.78)** เพราะยิ้ม + คำว่า รัก; Boom "ฉันแอบชอบคุณ" (คำ P < 0.5 ทั้งหมด) → **ไม่พูดอะไร** แทนที่จะพูดคำเดา.

เสียง (12 ประโยค × 7 อารมณ์ × 2 เสียง = 168)	ค่า
ฟังออก: CER ที่ ASR อิสระ (Qwen3-ASR base) ถอดได้ ↓	**0.06%** (เสียงเดิม MMS-TTS **8.2%**) — ทุกอารมณ์ ~0
อารมณ์ถูกส่งต่อ: pitch (เทียบเสียงกลางของตัวเอง) สอดคล้องกับ reference	**r = 0.78** (โกรธ +3–4 st, ตกใจ +4 st, กลัว +2–7 st, เศร้า −0.3–0.6 st)
— ช่วง pitch / ความดัง	r ≈ 0.0 / 0.22 — **ยังไม่ถูกส่งต่อ**
ความเร็ว: real-time factor	RTX 2050: **1.5** (32 steps) · CPU: ใช้ไม่ได้ (≫ 10) → ต้องมี GPU



ASR (เสียงคนได้ยิน → ข้อความ; และเป็น "หู" ตรวจเสียงสังเคราะห์) — Qwen3-ASR-0.6B:

CER ↓	base	LoRA lr 2e-4 ×1 epoch	LoRA lr 3e-5 ×1 (opt-in)
ประโยคสังเคราะห์ที่ไม่เคยเห็น (เสียงที่ไม่เคยเห็น)	4.2%	2.5%	**1.3%**
test-A (73 ประโยค held-out, VachanaTTS ชาย)	2.0%	3.3%	**1.8%**
วลีสั้นในชีวิตประจำวัน (asr_th, 96)	21.5%	22.5%	21.4%
FLEURS (เสียงคนจริง 100)	**6.7%**	11.9%	8.4%

ข้อมูล fine-tune (เฉลยถูกโดยโครงสร้าง): 418 วลีสั้น (แยก train/test ตามวลี, ตัดทุกข้อความที่อยู่ในชุด test ออก) → ElevenLabs 160 + held-out voice 62 + F5 clone 1,068 = 1,228 train (`cloud_s3/speech-data/asr/`). **ผล: เรียนเสียงสังเคราะห์ ไม่ใช่ภาษาไทย** — เสียงคนจริงแย่ลง → **ไม่ ship เป็น default** (adapter อยู่ใน `asr_lora/` แบบ opt-in). Qwen3-ASR base ก็ยังแย่กว่า Whisper-medium ของ reverse part บนวลีสั้น (21.5% vs 14.1%). สิ่งที่ต้องทำต่อ: ข้อมูลเสียงคนจริงพูดวลีสั้น (Common Voice th / อัดเอง) แทนเสียงสังเคราะห์.

---

7. Streaming + latency (`modules/stream.py`)

ทำไม: ค่าความเร็วต่อคลิปไม่ใช่ latency ของกล้องสด (GPT GAP 5). v9 มี runtime แบบ stateful: เฟรมเข้า buffer, pipeline รันทุก 0.5 s บนหน้าต่างจำกัด (≤ 8 s ย้อนหลังจากจุดที่ยืนยันแล้ว — งานต่อรอบมีขอบเขตไม่ว่าทำท่านานแค่ไหน), คำจะ **ยืนยัน** เมื่อจบไปแล้ว ≥ 0.8 s และอ่านได้คำเดิมที่ตำแหน่งเดิม 2 รอบติด (หรือมือพัก ≥ 0.8 s = จบ utterance); ที่เหลือเป็น **partial** (เทา, อาจเปลี่ยน). คำยืนยันแล้วไม่ถูกแก้ย้อนหลัง; กันคำซ้ำจากรอยตัดระหว่างรอบ. **วัดแบบซื่อสัตย์:** replay วิดีโอจริงตามเวลาจริง — รอบถัดไปเริ่มได้เมื่อรอบก่อนคำนวณเสร็จ และคำจะมีอยู่หลังเวลาคำนวณเท่านั้น.

28 วิดีโอจริง (iPhone ประโยค 5 · data_test 5 · team-drive 18), CPU laptop	ค่า
latency ต่อคำ (คำยืนยัน − ท่านั้นจบ) p50 / p95	**1.53 s / 2.40 s**
compute ต่อรอบ p50 / p95	304 / 486 ms (< 500 ms step → ตามทันเวลาจริง)
WER streaming vs batch (คลิปเดียวกัน)	**0.610** vs 0.645 (stream ไม่แย่กว่า batch)
คำซ้ำจากการ stream	**0**
partial ที่เปลี่ยนก่อนยืนยัน (flicker)	4.9 ครั้ง/คลิป (เฉลี่ย; Jack/iPhone 0–4, Boom 7–13)
MediaPipe (ไม่รวมข้างบน)	31 ms/เฟรม CPU server; บนเว็บรันในเบราว์เซอร์

ยังไม่ได้ต่อเข้าเว็บ (เว็บยังส่งทีละ utterance เมื่อพักมือ) — `StreamingTranslator` พร้อมสำหรับ websocket endpoint ในรอบถัดไป.

---

8. Production — Docker + API + lab3

`docker compose up --build` (gateway · web · sign-api · tts) — `sign-api` mount `models/model-v9` + `models/face-model` (ONNX Runtime + NumPy, ไม่มี PyTorch; landmark encoder เป็น ONNX). `/v1/info` → `version v9`. ส่งวิดีโอจริงเข้า API แล้วเทียบกับ Python (`SignPipeline(model_dir="models/model-v9")`):

วิดีโอ	ผลจาก API (Docker)	ตรงกับ Python	เวลา API (รวม MediaPipe)	โมเดล (tagger + spotting + face)	face affect (API)
Jack/พรุ่งนี้ผมจะไปเที่ยวประเทศจีน	พรุ่งนี้? ฉัน? ไป? เที่ยว? ประเทศ? จีน?	✅	21.5 s (MediaPipe 15.2 s)	1.5 s	เป็นกลาง ; ท่ามือเร็ว/แรง
Jack/สวัสดี ฉันชื่อ J ฉันชอบแมว	สวัสดี ฉัน ชื่อ **J?** ฉัน ชอบ แมว	✅	15.9 s	1.4 s	เป็นกลาง
Pitty/ฉันคิดถึงแม่	ฉัน? แม่	✅	6.7 s	0.6 s	เป็นกลาง
data_test/ฉันปลอบเพื่อนร้องไห้	เพื่อน ดู? สงสาร?	✅	11.7 s	1.3 s	**เศร้า (66%) เพราะมองลง · ยกริมฝีปากบน ; คำที่ทำ 'สงสาร' ; ท่ามือซ้า/เบา**

- เสียง: `speak=true` → `audio_wav_b64` จาก service `tts` (MMS, CPU) ทำงาน. **เสียง v1 (F5) ยังไม่อยู่ใน Docker** — ต้องใช้ GPU (CPU ช้าเกิน); ใช้ผ่าน `modules/speech.py` บนเครื่องที่มี GPU.
- เวลาส่วนใหญ่คือ MediaPipe ฝั่ง server (อัปโหลดวิดีโอ); บนเว็บ MediaPipe รันในเบราว์เซอร์ → API ใช้เฉพาะส่วนโมเดล (~0.6–1.5 s ต่อคลิป 4–10 s).
- Latency ส่วนโมเดลบน 37 วิดีโอจริง (Python, CPU): v8.1 843 ms/คลิป (98 ms ต่อวินาทีวิดีโอ) → v9 **872 ms** (102 ms/s, **+3%**); RSS 835 MB (เท่าเดิม); MediaPipe 31 ms/เฟรม.
- `lab3.ipynb` §9 เรียก API ที่รันอยู่จริงและเทียบผลกับ Python ในเซลล์เดียวกัน.
- **Docker Desktop บนเครื่องนี้เปิดไม่ขึ้น** ในตอนแรก (socket ค้าง `%LOCALAPPDATA%\Docker\run\userAnalyticsOtlpHttp.sock` "cannot be accessed") → ย้ายโฟลเดอร์ `run` ไปเป็น

`run.stale-20261028` แล้วเปิดใหม่ได้ (ลบโฟลเดอร์นั้นได้ภายหลัง).

---

9. ข้อจำกัด · สิ่งที่ควรทำต่อ (เรียงตามผลกระทบ)

1. **Recognition เพดานจาก encoder** (§1): ต้องการ encoder ที่เรียน "ท่าในประโยค" — hard-negative contrastive บนคู่ที่สับสน (กิน/หลาน, ยาย/ญาติ, คุณ/ฉัน) ด้วยประโยคต่อเนื่องสังเคราะห์จาก **คน train** (ห้ามใช้ TSL51 test signer). คาดว่าต้อง GPU job เดียว (~1 ชม. Spot A100 ≈ $1–1.5) — ไม่ได้ทำในรอบนี้เพราะงบ/ความเสี่ยง (v8 เคยถดถอยทั้ง chain เมื่อเปลี่ยน encoder).
2. **ข้อมูล:** คำสนทนาที่มีคน 1 คน 68 คำ (อยาก นำเสนอ งาน ...); ประโยคธรรมชาติหลายคน + ขอบเขตคำ (เพื่อเทรน tagger ที่ไม่พักมือ); คำนอก vocab ของ team-drive (แอบ ไหม จะ กัน ตลอดไป เกม).
3. **Enrollment ในเว็บ** คือทางที่ใกล้เป้า TSL51 ≤ 0.10 ที่สุด — ทำให้ผู้ใช้ลงทะเบียน 1–2 ตัวอย่าง/คำได้ง่าย.
4. Face: ชุดภาษามือไทยที่ติดป้ายอารมณ์ (แม้ 100–200 คลิป) เพื่อประเมินและปรับโดยตรง.
5. Speech: เสียงคนจริงสำหรับ ASR; ส่งต่อช่วง pitch/ความดังให้ดีขึ้น (reference หลายอันต่ออารมณ์ / intensity blend); service GPU ใน Docker.
6. Calibration: false-accept สูงขึ้นบนคำเดี่ยว (0.17) — พิจารณา `T` แยกตามกลุ่ม (คำเดี่ยว vs ประโยค) เมื่อมี tune data มากพอ.

---

10. Reproduce · ไฟล์ · Rollback · Cost

```
python main.py decision cache                       # front pass (CPU ~15 นาที) — + team-drive: --sets team
python main.py diagnose ledger                      # error ledger + oracle bounds (stage 1)
python main.py decision lmbank --out models/model-v9   # landmark encoder → onnx/lmenc.onnx + lm_bank.npz (+ eval bank)
python main.py decision tune --start v8.1 --grammar off --write     # ทุกค่าบน tune → models/model-v9 (~2 ชม. CPU)
python main.py decision report --versions v8.1,v9   # test + วิดีโอจริง + enrolled + latency →
artifacts/reports/decision_v9.json
python main.py face-data ravdess && python main.py face-model train && python main.py face-model signs
python main.py speech refs | asr-data | asr-train | asr-eval [--lora] | tts-eval | demo      # speech env: D:/SLM-
labs/envs/speech
```

โฟลเดอร์ / ไฟล์	อะไร
`models/model-v9/`	forward v9 (= Jack-model + `onnx/lmenc.onnx`, `lm_bank.npz`, spotting / calibration / class_prior ใหม่) — Docker default
`models/face-model/`	`face_emotion.npz` (NumPy), `model_card.json`, README
`models/speech-model-v1/`	`speech_config.json`, `refs/` + `refs.json`, `asr_lora/` (opt-in), README
`modules/`	`lmenc.py` (ONNX runtime), `face_model.py`, `speech.py`, `stream.py` (ใหม่); `pipeline.py` (reader, enrolled, face model, isotonic, ตัวอักษรหลังซื่อ), `decode.py`
`scripts/`	`diagnose.py`, `face_data.py`, `face_model.py`, `speech.py` (ใหม่); `decision.py` (team set, v9 tune/report, lmbank, enrolled)
`artifacts/baselines/v8.1/`	ค่าตั้ง v8.1 (baseline + rollback)
`lab3.ipynb`	ทดสอบ v9 ทุกชุด (คำนวณสด) + face + speech + Docker

Rollback → v8.1: `THAISLM_MODELS_DIR=./models/Jack-model docker compose up` (หรือ `SignPipeline(model_dir="models/Jack-model")`) — โค้ด v9 อ่านไฟล์ v8.1 ได้ (ไม่มี `read` = ไม่ใช้ landmark encoder).

Cost	
GCP (Vertex / Cloud Storage / Compute)	**$0** — ไม่ได้ใช้เลย (ตรวจหลังจบ §11)
ElevenLabs	free tier ~5.6k ตัวอักษร ($0)
AWS S3	ไม่ได้ push (อ่าน mirror ในเครื่อง)
ดาวน์โหลด	RAVDESS 12.7 GB (ลบหลังสกัด features), F5-TTS-THAI 1.3 GB + Qwen3-ASR 1.8 GB (`D:/SLM-labs/hf_cache`)

11. Cleanup

ที่	สถานะหลังจบ
GCP	ตรวจแบบอ่านอย่างเดียว: Vertex custom jobs **0** (asia-southeast1 / us-central1 / europe-west4) · bucket `temp-gpu-bucket-job` **0 object** (คง bucket ว่างไว้) · Compute VM **0** · disk **0** — รอบนี้ไม่ได้สร้างอะไรบน GCP เลย
Background process	ไม่มี python / kernel / tail ของงานนี้ค้าง · `docker compose down` แล้ว · Docker Desktop หยุดแล้ว
Workspace	ไฟล์ทดลอง/log ของรอบนี้ (`cache/v9`, 127 MB) ย้ายไป `D:\SLM-labs\_thaislm_v9_cleanup\` (ลบได้เลย); สคริปต์ทดลองอยู่นอก repo (scratchpad) · โค้ดใหม่ทุกไฟล์ถูกใช้โดย `main.py` / pipeline / lab3
คงไว้ (จำเป็น)	`cache/decision/` (635 MB, front pass ที่ `lab3.ipynb` ใช้ — สร้างใหม่ได้ด้วย `decision cache`) · `D:/SLM-labs/envs/speech` (speech env) · `D:/SLM-labs/hf_cache` (F5-TTS-THAI, Qwen3-ASR, vocos ≈ 3.2 GB) · `cloud_s3/face-data/`, `cloud_s3/speech-data/` (ข้อมูลที่เก็บเพิ่ม, ไม่อยู่ใน git)
ให้ลบเองได้	`D:\SLM-labs\_thaislm_v9_cleanup\` · `%LOCALAPPDATA%\Docker\run.stale-20261028` (socket ค้างของ Docker Desktop)
S3 (คำสั่งให้รันเองถ้าต้องการ push)	`aws s3 sync cloud_s3/face-data s3://dsi490-lake-signdata/agent_data/face-data --profile <AWS_PROFILE>` · `aws s3 sync cloud_s3/speech-data s3://dsi490-lake-signdata/agent_data/speech-data --profile <AWS_PROFILE>`
git	ยังไม่ commit (ผู้ใช้จัดการเอง, branch `jack_master`) — `models/model-v9`, `models/face-model`, `models/speech-model-v1` ใช้ Git LFS ตาม `.gitattributes`